Projet 3 - Concevez une application au service de la santé publique - Part 1

Table des matières

1. Introduction à la problématique

1.1 Contexte

Répondre à un appel à projets pour **trouver des idées innovantes d'applications en lien avec l'alimentation** lancé par l'agence "Santé publique France". Proposer une idée d'application.

1.2 Objectives

Concevoir une application à partir des données Open Food Facts

1) **Traiter le jeu de données** afin de **repérer des variables pertinentes** pour les traitements à venir. **Automatiser ces traitements** pour éviter de répéter ces opérations.

```
Le programme doit fonctionner si la base de données est légèrement modifiée
(ajout d'entrées, par exemple).
```

2) Tout au long de l'analyse, **produire des visualisations** afin de mieux comprendre les données. **Effectuer une analyse univariée** pour chaque variable intéressante, afin de synthétiser son comportement.

```
L'appel à projets spécifie que l'analyse doit être simple à comprendre pour un
public néophyte. Soyez donc attentif à la lisibilité : taille des textes, choix
des couleurs, netteté suffisante, et variez les graphiques (boxplots,
histogrammes, diagrammes circulaires, nuages de points…) pour illustrer au mieux
votre propos.
```

3) **Confirmer ou infirmer les hypothèses à l'aide d'une analyse multivariée. Effectuer les tests statistiques appropriés** pour vérifier la significativité des résultats.

4) **Élaborer une idée d'application**. Identifier des arguments justifiant la faisabilité (ou non) de l'application à partir des données Open Food Facts.

5) **Rédiger un rapport d'exploration et pitcher votre idée** durant la soutenance du projet.

1.3 Les Données

Le jeu de données publiques d'OpenFoodFacts : https://world.openfoodfacts.org/

> "Open Food Facts est une base de données sur les produits alimentaires faite par tout le monde, pour tout le monde."

Informations sur les definitions des differents variables : https://static.openfoodfacts.org/data/data-fields.txt

Les données d'OpenFoodFacts viennent des utilisatuers qui renseignent des informations via une application. Aujourd'hui, il y a plus que 1.9 Million produits d'alimentation renseignés. Cependent **un grand nombre d'entrées sont probablement erronées**, car l'application ne fait pas de contrôle ou de test pour les entrées de l'utilisateur.

1.4 Des Examples

- **Kaggle** : https://www.kaggle.com/openfoodfacts/world-food-facts/kernels?datasetId=20&sortBy=dateRun&language=Python
- **How much sugar?** : https://howmuchsugar.in/
- **PNNS** : https://www.mangerbouger.fr/PNNS

> "Lancé en 2001, le Programme national nutrition santé (PNNS) est un plan de santé publique visant à améliorer l'état de santé de la population en agissant sur l'un de ses déterminants majeurs : la nutrition. Pour le PNNS, la nutrition s'entend comme l'équilibre entre les apports liés à l'alimentation et les dépenses occasionnées par l'activité physique."

- **Nutriscore** : https://www.mangerbouger.fr/PNNS/Guides-et-documents/Le-Nutri-Score-pour-mieux-manger-en-un-coup-d-oeil

2. Les Imports et paramètres de sortie

2.1 Les libraries

In [1]:
```
#imports: regular expresssions, operating system, math operations
#import re,os,math
import os, random

#data modules
import numpy as np
import pandas as pd
import scipy as sp

#graphic modules
import matplotlib.pyplot as plt
import seaborn as sns
```

In [2]:
```
sns.set() #sets the theme of seaborn
#creates static png images of the plots within the notebook (other option: 'notebook' for inter
%matplotlib inline
```

2.2 Les paramètres de sortie

Ici, on peut choisir, si on veut voir les détails et sauvegarder les images, la data, etc.

In [3]:
```
print_details = True
save_figures = True
save_data = True
```

2.3 Les données

2.3.1 Télécharger les données

In [4]:
```
PATH_TO_DATA = os.getcwd()
openfoodfacts_df =  pd.read_csv(PATH_TO_DATA +'\\en.openfoodfacts.org.products.csv', sep = '\t'
```

```
c:\users\bookj\environments\jupenv\lib\site-packages\IPython\core\interactiveshell.py:3441: Dty
peWarning: Columns (0,8,13,19,20,21,22,23,27,28,29,31,52,64) have mixed types.Specify dtype opt
ion on import or set low_memory=False.
  exec(code_obj, self.user_global_ns, self.user_ns)
```

2.3.2 Un premier regard

Vérifier que l'import c'est bien passé et regarder la taille du jeu de données et à quel point il est rempli.

In [5]:
```
#check that the import went well
openfoodfacts_df.head()
```

Out[5]:

	code	url	creator	created_t	created_datetime	last_modified

	code	url	creator	created_t	created_datetime	last_modified
0	00000000000000225	http://world-en.openfoodfacts.org/product/0000...	nutrinet-sante	1623855208	2021-06-16T14:53:28Z	16238552C
1	0000000000017	http://world-en.openfoodfacts.org/product/0000...	kiliweb	1529059080	2018-06-15T10:38:00Z	156146371
2	0000000000031	http://world-en.openfoodfacts.org/product/0000...	isagoofy	1539464774	2018-10-13T21:06:14Z	153946481
3	0000000000003327986	http://world-en.openfoodfacts.org/product/0000...	kiliweb	1574175736	2019-11-19T15:02:16Z	162439076
4	0000000000004622327	http://world-en.openfoodfacts.org/product/0000...	kiliweb	1619501895	2021-04-27T05:38:15Z	161950189

5 rows × 186 columns

In [6]:
```
num_inds, num_cols = openfoodfacts_df.shape
print("Shape: ", num_inds, num_cols)
```

```
Shape:  1907318 186
```

In [7]:
```
#Look at the column names
openfoodfacts_df.columns.values
```

Out[7]:
```
array(['code', 'url', 'creator', 'created_t', 'created_datetime',
       'last_modified_t', 'last_modified_datetime', 'product_name',
       'abbreviated_product_name', 'generic_name', 'quantity',
       'packaging', 'packaging_tags', 'packaging_text', 'brands',
       'brands_tags', 'categories', 'categories_tags', 'categories_en',
       'origins', 'origins_tags', 'origins_en', 'manufacturing_places',
       'manufacturing_places_tags', 'labels', 'labels_tags', 'labels_en',
       'emb_codes', 'emb_codes_tags', 'first_packaging_code_geo',
       'cities', 'cities_tags', 'purchase_places', 'stores', 'countries',
       'countries_tags', 'countries_en', 'ingredients_text', 'allergens',
       'allergens_en', 'traces', 'traces_tags', 'traces_en',
       'serving_size', 'serving_quantity', 'no_nutriments', 'additives_n',
       'additives', 'additives_tags', 'additives_en',
       'ingredients_from_palm_oil_n', 'ingredients_from_palm_oil',
       'ingredients_from_palm_oil_tags',
       'ingredients_that_may_be_from_palm_oil_n',
       'ingredients_that_may_be_from_palm_oil',
       'ingredients_that_may_be_from_palm_oil_tags', 'nutriscore_score',
       'nutriscore_grade', 'nova_group', 'pnns_groups_1', 'pnns_groups_2',
       'states', 'states_tags', 'states_en', 'brand_owner',
       'ecoscore_score_fr', 'ecoscore_grade_fr', 'main_category',
       'main_category_en', 'image_url', 'image_small_url',
       'image_ingredients_url', 'image_ingredients_small_url',
       'image_nutrition_url', 'image_nutrition_small_url',
       'energy-kj_100g', 'energy-kcal_100g', 'energy_100g',
       'energy-from-fat_100g', 'fat_100g', 'saturated-fat_100g',
       '-butyric-acid_100g', '-caproic-acid_100g', '-caprylic-acid_100g',
       '-capric-acid_100g', '-lauric-acid_100g', '-myristic-acid_100g',
       '-palmitic-acid_100g', '-stearic-acid_100g',
       '-arachidic-acid_100g', '-behenic-acid_100g',
       '-lignoceric-acid_100g', '-cerotic-acid_100g',
       '-montanic-acid_100g', '-melissic-acid_100g',
       'monounsaturated-fat_100g', 'polyunsaturated-fat_100g',
       'omega-3-fat_100g', '-alpha-linolenic-acid_100g',
       '-eicosapentaenoic-acid_100g', '-docosahexaenoic-acid_100g',
       'omega-6-fat_100g', '-linoleic-acid_100g',
```

```
       '-arachidonic-acid_100g', '-gamma-linolenic-acid_100g',
       '-dihomo-gamma-linolenic-acid_100g', 'omega-9-fat_100g',
       '-oleic-acid_100g', '-elaidic-acid_100g', '-gondoic-acid_100g',
       '-mead-acid_100g', '-erucic-acid_100g', '-nervonic-acid_100g',
       'trans-fat_100g', 'cholesterol_100g', 'carbohydrates_100g',
       'sugars_100g', '-sucrose_100g', '-glucose_100g', '-fructose_100g',
       '-lactose_100g', '-maltose_100g', '-maltodextrins_100g',
       'starch_100g', 'polyols_100g', 'fiber_100g', '-soluble-fiber_100g',
       '-insoluble-fiber_100g', 'proteins_100g', 'casein_100g',
       'serum-proteins_100g', 'nucleotides_100g', 'salt_100g',
       'sodium_100g', 'alcohol_100g', 'vitamin-a_100g',
       'beta-carotene_100g', 'vitamin-d_100g', 'vitamin-e_100g',
       'vitamin-k_100g', 'vitamin-c_100g', 'vitamin-b1_100g',
       'vitamin-b2_100g', 'vitamin-pp_100g', 'vitamin-b6_100g',
       'vitamin-b9_100g', 'folates_100g', 'vitamin-b12_100g',
       'biotin_100g', 'pantothenic-acid_100g', 'silica_100g',
       'bicarbonate_100g', 'potassium_100g', 'chloride_100g',
       'calcium_100g', 'phosphorus_100g', 'iron_100g', 'magnesium_100g',
       'zinc_100g', 'copper_100g', 'manganese_100g', 'fluoride_100g',
       'selenium_100g', 'chromium_100g', 'molybdenum_100g', 'iodine_100g',
       'caffeine_100g', 'taurine_100g', 'ph_100g',
       'fruits-vegetables-nuts_100g', 'fruits-vegetables-nuts-dried_100g',
       'fruits-vegetables-nuts-estimate_100g',
       'collagen-meat-protein-ratio_100g', 'cocoa_100g',
       'chlorophyl_100g', 'carbon-footprint_100g',
       'carbon-footprint-from-meat-or-fish_100g',
       'nutrition-score-fr_100g', 'nutrition-score-uk_100g',
       'glycemic-index_100g', 'water-hardness_100g', 'choline_100g',
       'phylloquinone_100g', 'beta-glucan_100g', 'inositol_100g',
       'carnitine_100g'], dtype=object)
```

In [8]:

```
# look at the columns that have a mixed data type
if print_details:
    print(openfoodfacts_df.columns.values[[0,8,13,19,20,21,22,23,27,28,29,31,52,64]])

#set the dtype to 'string' for the columns that have mixed dtypes, in order to avoid any proble
for c in openfoodfacts_df.columns.values[[0,8,13,19,20,21,22,23,27,28,29,31,52,64]] :
    openfoodfacts_df[c] = openfoodfacts_df[c].astype('string')

#if I want to call the columns as a method their names cannot contain a '-'. Change the '-' to
openfoodfacts_df.columns = openfoodfacts_df.columns.str.replace('-', '_')
```

```
['code' 'abbreviated_product_name' 'packaging_text' 'origins'
 'origins_tags' 'origins_en' 'manufacturing_places'
 'manufacturing_places_tags' 'emb_codes' 'emb_codes_tags'
 'first_packaging_code_geo' 'cities_tags' 'ingredients_from_palm_oil_tags'
 'brand_owner']
```

In [9]:

```
column_completeness = openfoodfacts_df.notna().mean().sort_values(ascending = False)
y = 100 * column_completeness.values
x  = list(range(len(y)))
```

In [10]:

```
plt.figure(figsize=(16,5))
plt.bar(x, y, linewidth = 0, width = 0.5)
plt.xlabel("Colonnes")
plt.ylabel("Valeurs complètes (%)")
plt.xlim([-1, max(x)])
plt.ylim([0, max(y)])
if save_figures:
    plt.savefig(os.getcwd() + '\\Figures\\' + 'Intégralité_Des_Données', dpi = 200)
plt.show()
```

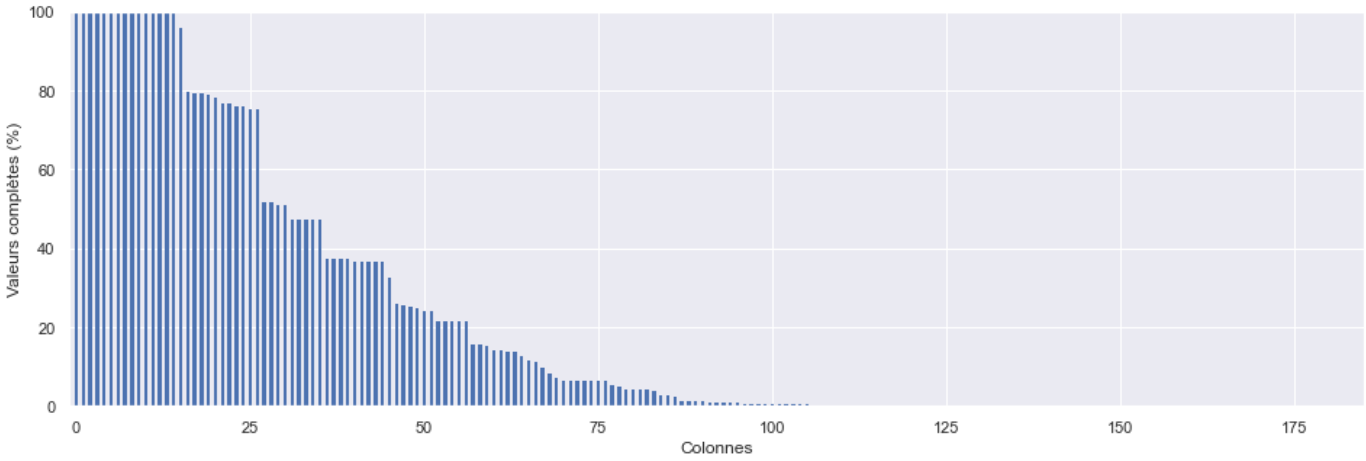

2.4 Conclusions

- Il y a **plus que 1.9 Millions de produits alimentaires** dans la base de données. Mais, il y a surement beaucoups des valeurs mal renseignées (valuers manquantes et erronées) et on peut assumer qu'il a des entrées dupliquées, car les données sont renseingées par des utilisateurs et ne sont que vérifier au fur et à mesure.
- Il y a **186 colonnes / variables**, mais **beaucoup sont peu peuplées**. La base de donnée d'OpenFoodFacts continue à évoluer.
- En finale, **seule une petit fraction des données sera utilisable** (pour des analyses). Mais 1% de 2 Million reste 20 000.

3. Les Variables

3.1 Les définitions

3.1.1 Informations nutritionnelles (minimale)

Dans beaucoup de pays, c'est obligatoire de déclarer des valeurs nutrionnelles pour la plupart des produits alimentaires. En générale, la déclaration nutrionnelle obligatoire inclut au minimum pour 100g ou 100ml:

Les valeurs nutritionnelles (minimales)	
la valeur énergétique (en kJ et kcal)	⇒ energy_100g / energy-kcal_100g
matières grasses (g) • dont acies gras saturés (g)	⇒ fat_100g • ⇒ saturated-fat_100g
glucides (g) • dont sucres (g)	⇒ carbohydrates_100g • ⇒ sugars_100g
protéines (g)	⇒ proteins_100g
sel (g)	⇒ salt_100g

L'énergie nutrionelle venant des macro-nutriments

On peut estimer la partie de l'énergie nutritionelle d'un produit alimentaire ventant des macro-nutriments (matières grasses, glucides et protéins). De base, cette énergie computée est représente l'énergie nutrionelle minimum d'un produit. Un produit peut contenir des autres nutriments qui contribuent à l'énergie nutitionelle qui ne font pas nécessairement partie des macro-nutriments, comme les alcools et les fibres alimentaires.

Macro-nutriments (qui font partie des valeurs nutritionelles minimales)	
glucides (à l'exception des polyols)	17 kJ/g - 4 kcal/g
polyols* (qui font partie des glucides)	10 kJ/g - 2.4 kcal/g
erythritol**** (est un type de polyol)	0 kJ - 0 kcal/g
protéins	17 kJ/g - 4 kcal/g
matières grasses	37 kJ/g - 9 kcal/g

Nutriments pas prise en compte pour l'énergie computée	
différents formes de salatrim**	25 kJ - 6 kcal/g
alcool (éthanol)	29 kJ - 7 kcal/g
acides organiques***	13 kJ/g - 3 kcal/g
fibres alimentaires	8 kJ - 2 kcal/g

*polyols: ce sont des alcools de sucre, souvent utilisées comme des édulscorants (https://en.wikipedia.org/wiki/Polyol)

** salatrim: un additif alimentaire, accepté comme substitut de graisse moins calorique (https://en.wikipedia.org/wiki/Salatrim)

*** acides organiques: utilisés dans la conservation des aliments (https://en.wikipedia.org/wiki/Organic_acid)

**** erythritol: un alcool de sucre, utilisé comme additif alimentaire et substitut du sucre (https://en.wikipedia.org/wiki/Erythritol)

Relations entre ces données:

Donnant les définitions et les informations sur les valeurs nutritionnelles ont peut constater certains règles et rélations entre les données qui peuvent servir comme vérification de la qualité des données et aider à éliminer des entrées erronées.

- Toutes ces variables doivent être positives.
- Les variables (à l'exception de l'energie) ne doivent pas excéder 100g.
- Egalment, leur somme ne doit pas excéder 100g non plus.
  - $\_fat_{100g} + \_carobhydrates_{100g} + \_proteins_{100g} + \_sel_{100g} \leq 100g$
    - $\_saturated\_fat_{100g} \leq \_fat_{100g}$
    - $\_sugars_{100g} \leq \_carbohydrates_{100g}$
- L'énergie doit être cohérent avec les quantities des autres variables*:
  - $\_energy_{100g} = 4.184\ \_energy\text{-}kcal_{100g}$
    - 1 kcal = 4.184 kJ
  - $37\ \_fat_{100g} + 17\ \_carbohydrates_{100g} + 17\ \_proteins_{100g} \leq \_energy_{100g}$
    - $1\ \_fat_{100g} = 37\ \_energy_{100g} = 9\ \_energy\text{-}kcal_{100g}$
    - $1\ \_carbohydrates_{100g} = 17\ \_energy_{100g} = 4\ \_energy\_kcal_{100g}$
    - $1\ \_proteins_{100g} = 17\ \_energy_{100g} = 4\ \_energy\_kcal_{100g}$
  - pour 100g: $\_energy_{100} \leq 3700$ (kJ) (la matière grasse a le plus d'énergie par gramme)

* On note que les conversions des quantitiés de nutriments en énergie nutritionelle sont simplifiées et arrondies. On peut attendre qu'il va avoir des variations.

Sources:

- https://fr.wikipedia.org/wiki/Information_nutritionnelle
- https://www.legislation.gov.uk/uksi/1996/1499/schedule/7/made
- Règlement (UE) n o 1169/2011 du Parlement européen et du Conseil du 25 octobre 2011 concernant l'information des consommateurs sur les denrées alimentaires (https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A02011R1169-20180101)

3.1.2 Nutri-Score

Sources:

- https://www.santepubliquefrance.fr/determinants-de-sante/nutrition-et-activite-physique/articles/nutri-score

Nutri-Score, c'est quoi ?

- Un logo apposé en face avant des emballages qui informe sur la qualité nutritionnelle des produits sous une forme simplifiée et complémentaire à la déclaration nutritionnelle obligatoire (fixée par la réglementation européenne)
- Basé sur une échelle de 5 couleurs : du vert foncé au orange foncé
- Associé à des lettres allant de A à E pour optimiser son accessibilité et sa compréhension par le consommateur

Comment est-il attribué ?

- Le logo est attribué sur la base d'un score prenant en compte pour 100 gr ou 100 mL de produit, la teneur :
  - en nutriments et aliments à favoriser (fibres, protéines, fruits, légumes, légumineuses, fruits à coques, huile de colza, de noix et d'olive),
  - et en nutriments à limiter (énergie, acides gras saturés, sucres, sel).
- Après calcul, le score obtenu par un produit permet de lui attribuer une lettre et une couleur.

Variables nécessaire pour calculer le NutriScore:

la valeur énergétique (kJ)	⇒ energy_100g
sucres (g)	⇒ sugars_100g
acies gras saturés (g)	⇒ saturated-fat_100g
sodium (mg)	⇒ sodium_100g / 1000
fruits, légumes, légumineuses, fruits à coque et huiles de colza, de noix et d'olive (%)	⇒ fruits-vegetables-nuts_100g (fruits-vegetables-nuts-estimate_100g)
fibres (g)	⇒ fiber_100g
protéines (g)	⇒ proteins_100g

Relations entre les variables

- Les variables necessaire pour calculer le NutriScore qui font partie de l'information nutritionnelle minimale
  - energy_100g, sugars_100g, saturated-fat_100g, proteins_100g
- La quantité de sodium peut être dérivée de la quantité de sel
  - $\_sodium_{100g} = 0.4 \ \_salt_{100g}$
- Les variables utilisées pour le NutriScore qui ne font pas partie de l'information nutritionnelle minimale
  - fibres_100g, fruits-vegetables-nuts_100g

3.1.3 NOVA classification

Sources: https://fr.wikipedia.org/wiki/NOVA_(nutrition)

La NOVA classification, c'est quoi ?

La classification NOVA est une répartition des aliments en quatre groupes en fonction du degré de transformation des matières dont ils sont constitués:

- Groupe 1 : Aliments peu ou non transformés
    - Ces aliments peuvent être soumis à un ou plusieurs traitements dans le but de prolonger la durée de vie ou de diversifier la préparation des aliments (grillage de graines de café, fermentation du lait pour les yaourts...) mais qui ne modifient pas intrinsèquement les propriétés nutritionnelles des aliments. Les éléments de ce groupe sont susceptibles de contenir des additifs dans le but de conserver les propriétés de l'aliment de base.
    - les viandes et poissons frais, les fruits de mer, les œufs, le lait pasteurisé, les yaourts natures, le beurre, le café, les épices, les fruits frais, pressés, réfrigérés, congelées, séchés, les céréales, champignons, légumes, tubercules, noix et graines
- Groupe 2 : Ingrédients culinaires
    - Ces produits sont obtenus grâce à diverses transformations physiques et chimiques (pressage, raffinage, meulage...) des aliments du groupe 1. Ils ne sont que rarement consommés en l'absence d'aliments du groupe 1. Ils servent en effet à préparer, assaisonner et cuire les aliments du groupe 1. Ils ont des propriétés et usages nutritionnels très différents de ceux du groupe 1.
    - le sucre, les huiles végétales, les beurres et graisses animales, le lard, les soupes, le vinaigre, le lait de noix de coco, la fécule de maïs, les amidons, le sirop d'érable et le miel
- Groupe 3 : Aliments transformés
    - Ce sont des aliments constitués d'un ou deux ingrédients, qui ont subi des transformations assez simples, et qui sont fabriqués à partir d'un aliment du groupe 1 auquel on a ajouté un aliment du groupe 2, dans l'objectif de leur conférer une durée de vie plus longue, d'améliorer ou de modifier leur goût, et également d'augmenter leur résistance aux microbes.
    - Les boissons alcoolisées telles que le cidre ou le vin, qui sont réalisées à partir de la fermentation d'aliments du premier groupe, font partie du groupe 3.
- Groupe 4 : Aliments ultra-transformé
    - Les aliments du groupe 4 sont, quant à eux, réalisés généralement à partir de 5 ingrédients ou plus, dans le cadre d'une transformation industrielle complexe. Ces aliments ont pour caractéristiques d'être riches en sucres, en sel et en matières grasses ajoutées. Ils sont, le plus souvent, constitués de substances industrielles qui n'ont pas d'équivalent domestique (caséine, lactosérum, huiles hydrogénées...) et contiennent en général des additifs, afin notamment d'améliorer le goût des aliments et de camoufler les saveurs indésirables des produits finaux incorporés tels que les colorants, les émulsifiants, ou encore les édulcorants.

3.1.4 Eco-score

Sources: https://docs.score-environnemental.com/

Eco-score, c'est quoi ?

L'Eco-score est un indicateur représentant l'impact environnemental des produits alimentaires. Il classe les produits en 5 catégories (A, B, C, D, E), de l'impact le plus faible, à l'impact le plus élevé. L'impact

environnemental tient compte de plusieurs facteurs sur la pollution de l'air, des eaux, des océans, du sol, ainsi que les impacts sur la biosphère.

Il prend en compte :

- ingrédients spécifiques (impacts important sur la biodiversité et les écosystèmes)
- saisonnalité des ingrédients (fruits et légumes de saison, pas de serres chauffées)
- impacts environnementaux (impacts de la production, du transport et des emballages des ingrédients, sur la biodiversité notamment; analyse du cycle de vie du produit)
- emballages (materiaux, recyclabilité, fin de vie, séparabilité)
- provenance & transparence (origine des ingrédients)
- modes de production (labels environnementaux, pêche, etc.)

- On note que ce score est expérimental. Il vient d'être mis en oeuvre et est encore en train d'être améliorer.

3.2 Types des variables (entre autres)

- **identificateur** : code
  - product_name (signification humaine), ... , generic_name

- variables qualitatives :
  - nominale :
    - **Type alimentation** : pnns_groups_1, pnns_groups_2, categories, categories_en, categories_tags, main_category ,main_category_en
    - **Pays** : countries, countries_en, countries_tags
    - **Ingrédients** : ingredients_text, additives_en, additives_tags, allergens, traces, traces_en, traces_tags, ...
    - **Etiquettes** : labels, labels_en, labels_tags
    - **Emballages** : packaging, packaging_tags
    - **Lieu de vente / de production** : stores, purchase_places, manufacturing_places, manufacturing_places_tags, emb_codes, emb_codes_tags, ...
  - ordinale :
    - **Evaluation** : nutriscore_grade, nova_group, ecoscore_grade_fr

- variables quantitatives :
  - continue :
    - **Valeurs Nutritionelles** : energy_100g, energy_kcal_100g, fat_100g, saturated-fat_100g, carbohydrates_100g, sugars_100g, saturated-fat_100g, proteins_100g, salt_100g, sodium_100g, ... , fiber_100g, ... ,'fruits-vegetables-nuts-estimate_100g', fruits-vegetables-nuts_100g, ... , energy-kj_100g, ... , alcohol_100g, ... , **xxx_100g**
  - discrète :
    - **Nombre de type d'ingrédients** : additives_n, ingredients_from_palm_oil_n, ingredients_that_may_be_from_palm_oil_n
    - **Score de l'Evaluation** : nutriscore_score, nutrition-score-fr_100g, ecoscore_score_fr

Dans le fichier .txt , il y a d'autre noms / tags listés.

3.3 Les fonctions

In [11]:

```
def sample_column(data, column, sample_size=15) :
    s = data[column]
    comp = s.count()/len(s)
    print(f"Column '{column}' is {100*comp.round(2)} % complete.")
```

```
    print()
    print(s.describe())
    print()
    list_unique = list(s.unique())
    len_unique = len(list_unique)
    sample_size = sample_size if sample_size <= len_unique else len_unique
    for i in random.sample(list_unique, k = sample_size) :
        print()
        print(i)
        print()
        print("Items with this entry: ")
        print(data[data[column] == i]['product_name'])
        print()
```

In [12]:

```
def compare_column_completeness(data, columnlist):
    data = data[columnlist].copy()
    output = []
    for i, c in enumerate(columnlist) :
        tmp = data.dropna(subset = [c]).count()
        l = tmp[c]
        tmp = tmp / l
        output.append(tmp.values)
    output = np.array(output)
    sns.heatmap(output, annot = True, xticklabels = columnlist, yticklabels = [ci + "_100%" for
```

In [13]:

```
def compare_two_related_columns(data_df, columns, lines = [], vlines = [], savefigure = False,
    '''Lines and vlines are list of tuples containing the data and **kwargs to lines added on t
    The data for lines is slope, offset of the curve and for vlines simply the position of the
    ax = data_df.plot.scatter(x=columns[0], y =columns[1], c='blue', **kwargs)
    xlim = ax.get_xlim()
    ylim = ax.get_ylim()
    xdata = list(xlim)
    for ll in list(lines):
        if isinstance(ll, tuple) :
            m = ll[0]
            b = ll[1]
            kwargs_l = ll[2] if len(ll) > 2 else {}
            plt.plot(xdata, [m*i + b for i in xdata], **kwargs_l)
        else :
            m = lines[0]
            b = lines[1]
            kwargs_l = lines[2] if len(lines) > 2 else {}
            plt.plot(xdata, [m*i + b for i in xdata], **kwargs_l)
    vlines = [vlines,] if not isinstance(vlines,list) else list(vlines)
    for vl in vlines:
        if isinstance(vl,tuple) :
            v = vl[0]
            kwargs_v = vl[1] if len(vl) > 1 else {}
            plt.axvline(v, **kwargs_v)
        else :
            v = vl
            kwargs_v = vlines[1] if len(list(vlines)) > 1 else {}
            plt.axvline(v, **kwargs_v)
    if savefigure:
        plt.savefig(os.getcwd() + '\\Figures\\' + 'ColumnComparison_' + columns[0] + '_vs_' + c
    ax.set_ylim(ylim)
    ax.set_xlim(xlim)
```

3.4 Nettoyer le jeu de données

Regarder que sont les variables avec un taux de remplissage plus ou moins élévé et voir si elle peuvent servir à créer une application en lien avec l'alimentation.

In [14]:

```
column_completeness[(column_completeness <= 0.6) & (column_completeness >= 0.4)]
```

Out[14]:
```
brands                        0.514968
brands_tags                   0.514934
image_nutrition_small_url     0.510036
image_nutrition_url           0.510036
categories                    0.472468
categories_tags               0.472466
main_category_en              0.472466
categories_en                 0.472466
main_category                 0.472466
dtype: float64
```

In [15]:
```
col_name = 'fruits_vegetables_nuts_100g'
sample_column(openfoodfacts_df, col_name, sample_size=15)
```

```
Column 'fruits_vegetables_nuts_100g' is 0.0 % complete.

count    8795.000000
mean       34.111718
std        36.461854
min         0.000000
25%         0.000000
50%        20.300000
75%        60.000000
max       100.000000
Name: fruits_vegetables_nuts_100g, dtype: float64


70.2

Items with this entry:
1737158    Alubia roja cocida
Name: product_name, dtype: object


19.5

Items with this entry:
747952                                    Tarte aux Poireaux
748009            Tarte aux Poireaux, gratinée à l'emmental
748184    Merlu blanc compotée à la provençale, linguine...
948645                               Tout simplement mangue
Name: product_name, dtype: object


36.3

Items with this entry:
945276     Sorbet pommes vertes avec morceaux de pomme
1636609            Sauce bolognaise et fromages Italie
Name: product_name, dtype: object


47.8

Items with this entry:
774611    Mouliné de légumes verts
Name: product_name, dtype: object


3.8

Items with this entry:
787997      Poulet façon Kebab et semoule
935714                      Caldo pescado
949545    Muesli croustillant aux fraises
Name: product_name, dtype: object


53.1

Items with this entry:
946517    Salade jambon emmental crudités
Name: product_name, dtype: object
```

```
17.57

Items with this entry:
747892    Tartes du monde - L'Indienne
Name: product_name, dtype: object


43.25

Items with this entry:
950451    Spaghetti a la bolognaise
Name: product_name, dtype: object


3.92

Items with this entry:
947159                     Gaufrettes fraise X18
947422    Cocktail sans alcool citron vert kiwi
951561                       Sirop de citron bio
Name: product_name, dtype: object


0.53

Items with this entry:
946313    Court bouillon
Name: product_name, dtype: object


45.7

Items with this entry:
945833    Olives vertes dénoyautées
Name: product_name, dtype: object


10.33

Items with this entry:
946378    Fromage frais framboise 5,5%mg
Name: product_name, dtype: object


68.63

Items with this entry:
948249    Poêlée de légumes capriciosa
Name: product_name, dtype: object


42.9

Items with this entry:
1737598    Rollitos de primavera
Name: product_name, dtype: object


20.1

Items with this entry:
745334    Mélange au thon et petits légumes à la catalane
Name: product_name, dtype: object
```

3.4.1 Les Catégories d'Alimentation

On va utiliser les variables **'pnns_groups_1' et 'pnns_groups_2'**, car les variables 'categories', 'main_category', etc. ... ne sont pas reneignées d'une façon cohérente. Les variables de type 'categories' sont des listes qui contiennet plusieurs catégories, des fois dans différents languages. Les variables de type

'main_category' n'ont qu'une catégorie, mais elles ne sont pas toutes dans la même language. Un préfix donne la language de la catégorie. Pour 'main_category_en' les catégories en anglais n'ont pas de préfix. On a l'impression que les utilisateurs peuvent renseigner n'import quelles catégories. On peut imaginer que ces 'tags' vont être traîter eventuellement.

In [16]:
```
openfoodfacts_df['pnns_groups_1'].unique()
```

Out[16]:
```
array(['unknown', 'Fat and sauces', 'Composite foods', 'Sugary snacks',
       'Fruits and vegetables', 'Fish Meat Eggs', 'Beverages',
       'Milk and dairy products', 'Cereals and potatoes', 'Salty snacks',
       'Alcoholic beverages', nan, 'sugary-snacks'], dtype=object)
```

Les catégories PNNS

Les deux catégories PNNS (pnns_groups_1 et pnns_groups_2) contiennent aussi les valeurs : 'unknown' et 'nan'. Alors, même si le taux de remplissage de pnns_groups_1 et pnns_groups_2 est indiqué 100%, la catégorie des éléments n'est pas nécessairement connue / renseignée. De plus, dans ces deux variables, il y a des doublons :

- nan = 'unknown'
- 'sugary-snacks' = 'Sugary snacks'
- 'Pizza pies and quiche' = 'Pizza pies and quiches'
- 'pastries' = 'Pastries' On va corriger ces valeurs.

In [17]:
```
openfoodfacts_df.replace(to_replace={'pnns_groups_1' : {np.nan:'unknown',
                                                        'sugary-snacks':'Sugary snacks'},
                                     'pnns_groups_2' : {np.nan:'unknown',
                                                        'Pizza pies and quiche' : 'Pizza pies a
                                                        'pastries' : 'Pastries'}},
                         inplace = True)
if print_details :
    print(openfoodfacts_df[['pnns_groups_1', 'pnns_groups_2']].describe())
```

```
       pnns_groups_1 pnns_groups_2
count        1907318       1907318
unique            11            40
top          unknown       unknown
freq         1174482       1174480
```

In [18]:
```
openfoodfacts_df[['pnns_groups_1','pnns_groups_2']].value_counts(sort=False)
```

Out[18]:
```
pnns_groups_1            pnns_groups_2
Alcoholic beverages      Alcoholic beverages                 16780
Beverages                Artificially sweetened beverages     9361
                         Fruit juices                         9694
                         Fruit nectars                        1369
                         Plant-based milk substitutes         5816
                         Sweetened beverages                 23078
                         Teas and herbal teas and coffees     1631
                         Unsweetened beverages               10485
                         Waters and flavored waters           6851
Cereals and potatoes     Bread                               22023
                         Breakfast cereals                    9507
                         Cereals                             39951
                         Legumes                              8949
                         Potatoes                             2958
Composite foods          One-dish meals                      42642
                         Pizza pies and quiches               8589
                         Sandwiches                           4050
Fat and sauces           Dressings and sauces                49524
                         Fats                                21908
Fish Meat Eggs           Eggs                                 3664
                         Fish and seafood                    27434
                         Meat                                30615
```

```
                          Offals                          1248
                          Processed meat                 39591
Fruits and vegetables     Dried fruits                    6074
                          Fruits                         17038
                          Soups                           2819
                          Vegetables                     30848
Milk and dairy products   Cheese                         45411
                          Dairy desserts                  6831
                          Ice cream                       7032
                          Milk and yogurt                32513
Salty snacks              Appetizers                     11578
                          Nuts                            7970
                          Salty and fatty products       14283
Sugary snacks             Biscuits and cakes             63058
                          Chocolate products             14444
                          Pastries                        6219
                          Sweets                         69000
unknown                   Alcoholic beverages                2
                          unknown                      1174480
dtype: int64
```

3.4.2 Les informations nutritionelles (minimales)

On va regarder de plus près ces valeurs nutritionelles, car ce sont les valeurs le plus renseignées et elles sont souvent obligatoirement affichées sur les étiquettes des produits.

energy_100g, energy_kcal_100g, energy-kj_100g, fat_100g, saturated-fat_100g, carbohydrates_100g, sugars_100g, proteins_100g, salt_100g, sodium_100g

In [19]:
```
nutritional_values = ['energy_100g', 'energy_kcal_100g', 'energy_kj_100g',
                      'fat_100g', 'saturated_fat_100g',
                      'carbohydrates_100g', 'sugars_100g',
                      'proteins_100g',
                      'salt_100g', 'sodium_100g',
                      'alcohol_100g', 'fiber_100g']
```

In [20]:
```
compare_column_completeness(openfoodfacts_df, nutritional_values)
```

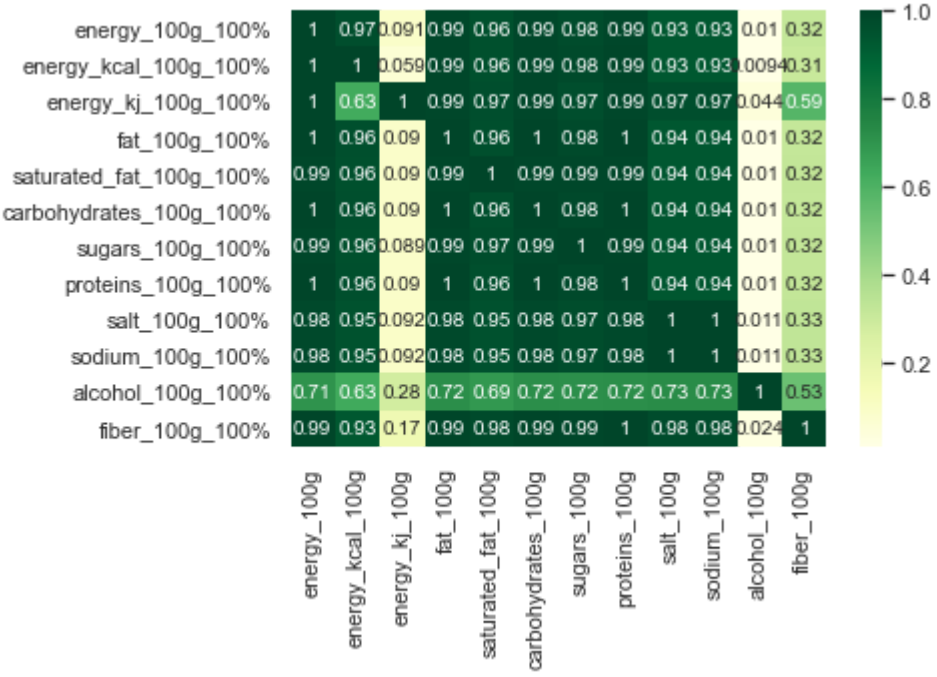

Éliminer les erreurs évidentes

On va **éliminer** tous les éléments avec des **valeurs manquantes et les erreurs évidentes**:

- les variables (sauf pour les énergétiques) avec les valeurs supérieure à 100g

- les variables avec une entrée négative
- une quantité d'énergie de plus de 3780kJ (La quantité maximale d'énergie qu'un produit peut avoir, c'est 3700kJ, dans ce cas, il s'agirait de 100% de matières grasses. On utilise 3780 kJ pour le max au ca où les calcules était fait pour 9kcal, i.e. pour prendre en compte des petites déviations liées au)
- si l'énergie en kcal ne correspond pas à celui en kJ. Ca indique que l'utilisateur n'a pas bien renseignés les données. (1 kcal = 4.184 kJ). On va donner une marge d'erreur de 10%.
- plus de sucres que de glucides
- plus de acies gras saturés que de matières grasses

De plus on va supprimer la variable 'energy_kj_100g', car elle n'apporte pas d'information supplémentaire et n'est pas vraiment bien renseignée. C'est le doublon de 'energy_100g' et les valeurs ont l'air de correspondre à celui de 'energy_100g'.

Les nécessaires constants

In [21]:
```
KCAL_TO_KJ = 4.184
KJ_TO_KCAL = 1/KCAL_TO_KJ
MAX_G = 100
MAX_KJ = 3780
MAX_KCAL = round(MAX_KJ*KJ_TO_KCAL)
NA_IN_SALT = 0.4
```

In [22]:
```
compare_two_related_columns(openfoodfacts_df, ['energy_100g', 'energy_kcal_100g'],
                            [(KJ_TO_KCAL, 0, {'color' : 'black', 'linewidth' : 2}),
                             (1, 0, {'color' : 'red', 'linewidth' : 2}),
                             (KCAL_TO_KJ, 0, {'color' : 'red', 'linewidth' : 2})],
                            [MAX_KJ],
                            xlim = [0,2*MAX_KJ], ylim = [0,2*MAX_KCAL], marker = ".", alpha = 0
compare_two_related_columns(openfoodfacts_df, ['energy_100g', 'energy_kj_100g'],
                            [(1, 0, {'color' : 'black'})],
                            [MAX_KJ],
                            xlim = [0,2*MAX_KJ], ylim = [0,2*MAX_KJ], marker = ".", alpha = 0.5
compare_two_related_columns(openfoodfacts_df, ['salt_100g', 'sodium_100g'],
                            [(NA_IN_SALT, 0, {'color' : 'black'})],
                            [MAX_G],
                            xlim = [0,2*MAX_G], ylim = [0,2*MAX_G*NA_IN_SALT], marker = ".", al
compare_two_related_columns(openfoodfacts_df, ['carbohydrates_100g', 'sugars_100g'],
                            [(1, 0, {'color' : 'black'})],
                            [MAX_G],
                            xlim = [0,2*MAX_G], ylim = [0,2*MAX_G], marker = ".", alpha = 0.5)
compare_two_related_columns(openfoodfacts_df, ['fat_100g', 'saturated_fat_100g'],
                            [(1, 0, {'color' : 'black'})],
                            [MAX_G],
                            xlim = [0,2*MAX_G], ylim = [0,2*MAX_G], marker = ".", alpha = 0.5)
```

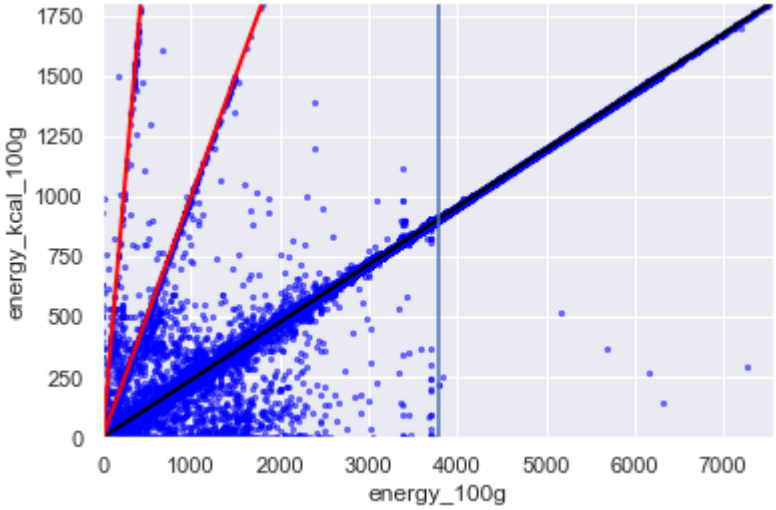

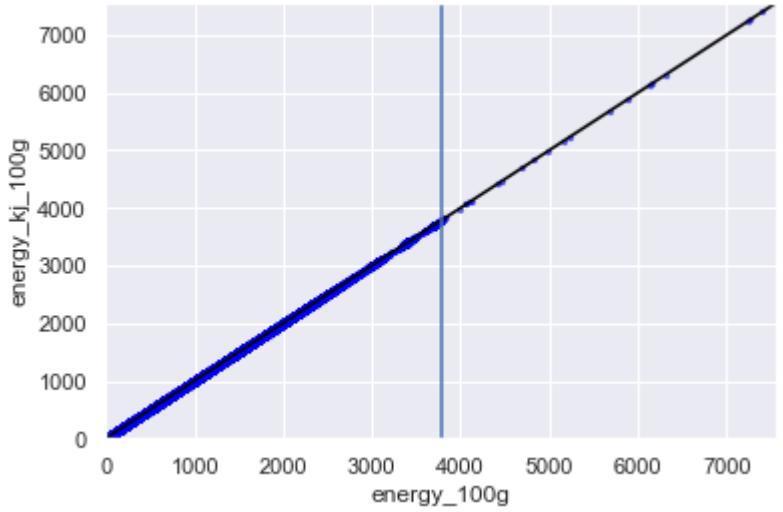
energy_kj_100g
energy_100g
0
1000
2000
3000
4000
5000
6000
7000

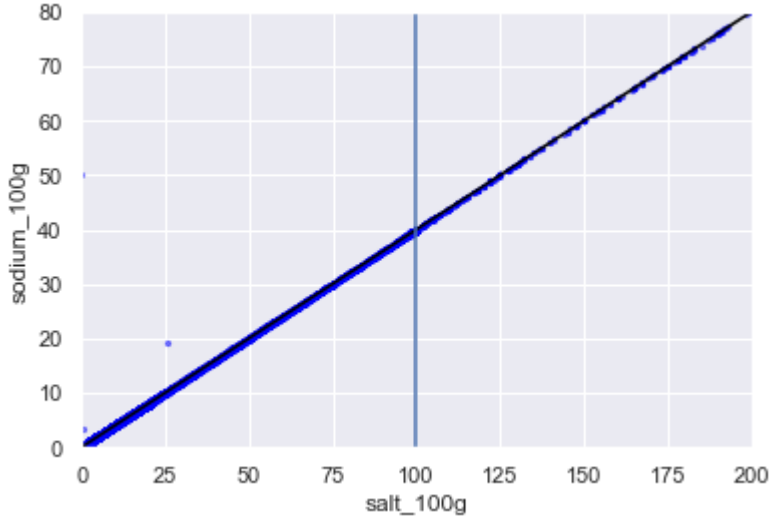
sodium_100g
salt_100g
0
10
20
30
40
50
60
70
80
0
25
50
75
100
125
150
175
200

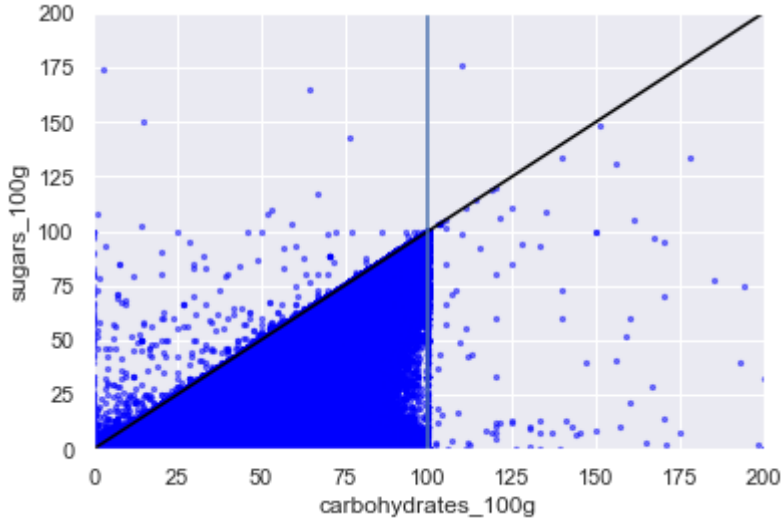
sugars_100g
carbohydrates_100g
0
25
50
75
100
125
150
175
200

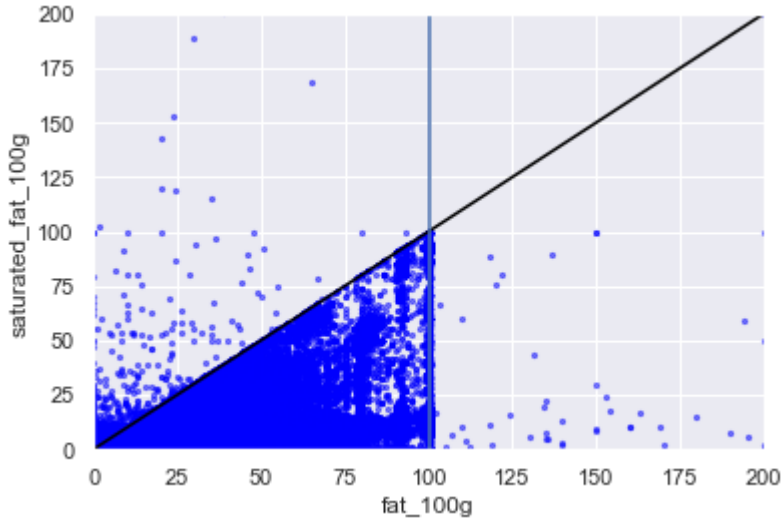
saturated_fat_100g
fat_100g
0
25
50
75
100
125
150
175
200

In [23]:

```
compare_two_related_columns(openfoodfacts_df, ['fat_100g', 'saturated_fat_100g'],
                            [(1, 0, {'color' : 'black'})],
                            [MAX_G],
                            xlim = [0,150], ylim = [0,150], savefigure = save_figures,marker =
```

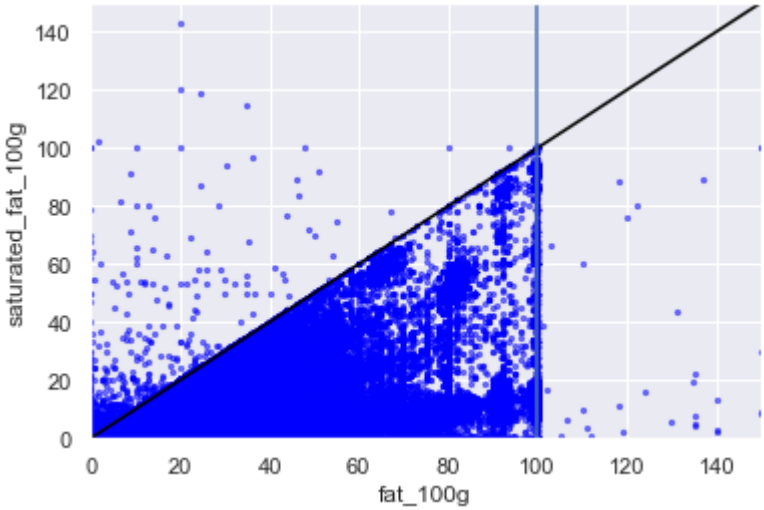

In [24]:
```
nutritional_values = ['energy_100g', 'energy_kcal_100g',
                      'fat_100g', 'saturated_fat_100g',
                      'carbohydrates_100g', 'sugars_100g',
                      'proteins_100g',
                      'salt_100g', 'sodium_100g']
nutritional_values_df = openfoodfacts_df[nutritional_values].copy()#.dropna(axis = 0)
```

In [25]:
```
is_empty = np.where(nutritional_values_df.isnull().sum(axis=1) >= 1, True, False)

pd.Series(~is_empty).value_counts()#/pd.Series(~is_empty).value_counts().sum()
```

Out[25]:
```
True     1307976
False     599342
dtype: int64
```

In [26]:
```
nutritional_values_df = nutritional_values_df.loc[~is_empty].copy()
```

In [27]:
```
exceeds_100g = np.array([True if any(i > 100 or i < 0 for i in a) else False for a in zip(
                                                    nutritional_values_df.fat_100g,
                                                    nutritional_values_df.carbohydrates_100g,
                                                    nutritional_values_df.proteins_100g,
                                                    nutritional_values_df.salt_100g,
                                                    nutritional_values_df.sugars_100g,
                                                    nutritional_values_df.saturated_fat_100g,
                                                    nutritional_values_df.sodium_100g)])

exceeds_energy = np.array([True if i > 3780 or i < 0 else False for i in nutritional_values_df.

exceeds_carbohydrates = np.array([True if i > j else False for i, j in zip(nutritional_values_d
                                                                           nutritional_values_d

exceeds_fat = np.array([True if i > j else False for i, j in zip(nutritional_values_df.saturate
                                                                 nutritional_values_df.fat_100g

energies_mismatch = np.array([True if i < 0.9 * KJ_TO_KCAL * j or i > 1.1 * KJ_TO_KCAL * j else
                                                                   nutritional_values_df.energ
                                                                   nutritional_values_df.energ

select = ~(exceeds_100g | exceeds_energy | exceeds_carbohydrates | exceeds_fat | energies_misma
```

In [28]:
```
pd.Series(select).value_counts()#/pd.Series(select).value_counts().sum()
```

Out[28]:
```
True     1295445
False      12531
dtype: int64
```

In [29]:
```
nutritional_values_df = nutritional_values_df.loc[select].copy()
```

In [30]:
```
if print_details :
    compare_two_related_columns(nutritional_values_df, ['energy_100g', 'energy_kcal_100g'],
                                [KJ_TO_KCAL, 0, {'color': 'black'}], MAX_KJ, marker = ".", alph
    compare_two_related_columns(nutritional_values_df, ['carbohydrates_100g', 'sugars_100g'],
                                [1, 0, {'color' : 'red'}], MAX_G, marker = ".", alpha = 0.1)
    compare_two_related_columns(nutritional_values_df, ['fat_100g', 'saturated_fat_100g'],
                                [1, 0, {'color' : 'red'}], MAX_G, savefigure = save_figures, ma
```

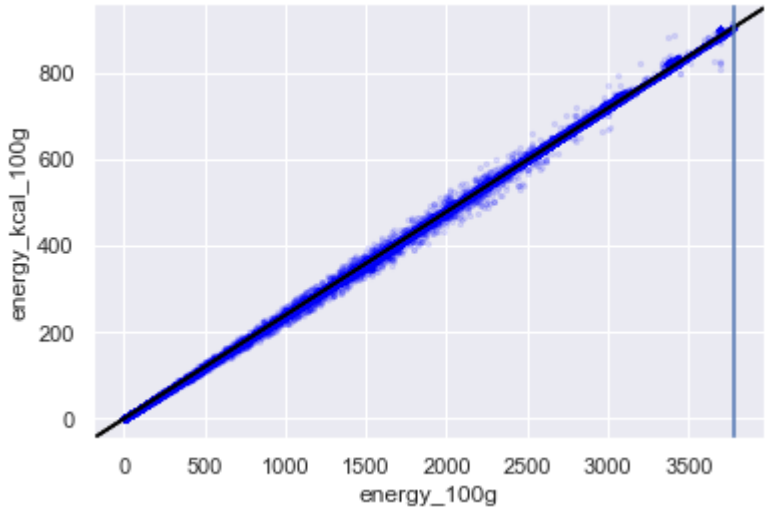

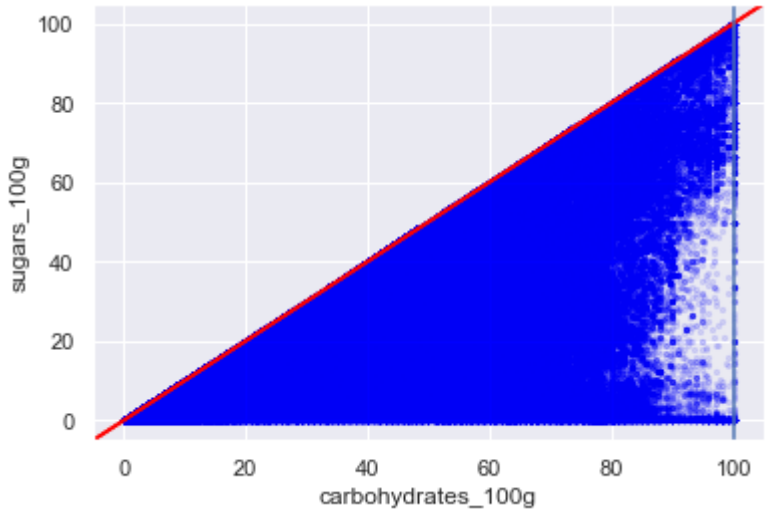

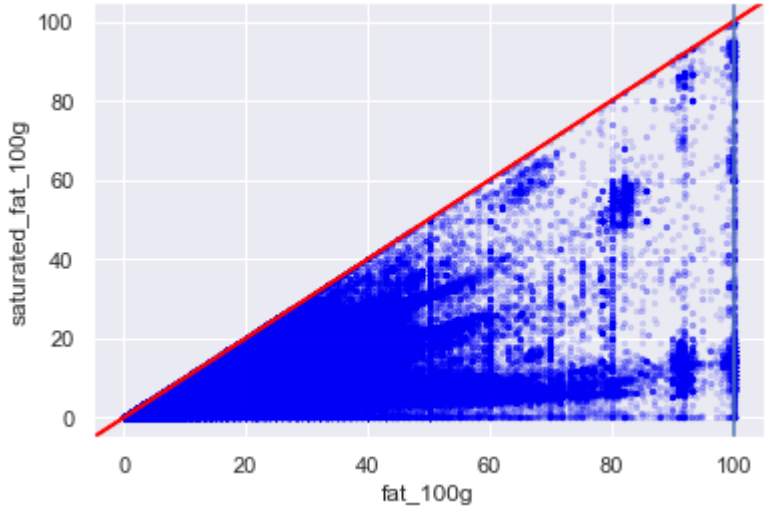

La somme des macro-nutriments

De plus, on va vérifier que la somme des macro-nutriments (matières grasses, glycides, protéins) et du sel ne surpasse pas les 100g non-plus. Pour ça, on va créer une variable 'g_sum', qui est la somme des macro-nutriments plus le sel. On va **éliminer les élements pour lequels le somme est plus grand que 102g**. (On va laisser une marge de 2% d'erreur, pour tenir compte des erreurs d'arrondissement.

In [31]:
```
nutritional_values_df['g_sum'] = nutritional_values_df.fat_100g \
                               + nutritional_values_df.carbohydrates_100g \
                               + nutritional_values_df.proteins_100g \
                               + nutritional_values_df.salt_100g


print(nutritional_values_df['g_sum'].describe())

fig, ax = plt.subplots(figsize = (10,4))
ax.set_xlim(0,110)
plt.hist(nutritional_values_df['g_sum'], bins=[0,10,20,30,40,50,60,70,80,90,100.1,400])
plt.xlabel("Somme des macro-nutriments + el (g)")
plt.ylabel("Fréquence")
```

```
count    1.295445e+06
mean     5.254046e+01
std      3.173928e+01
min      0.000000e+00
25%      2.414782e+01
50%      5.030000e+01
75%      8.519000e+01
max      3.960000e+02
Name: g_sum, dtype: float64
```

Out[31]:
```
Text(0, 0.5, 'Fréquence')
```

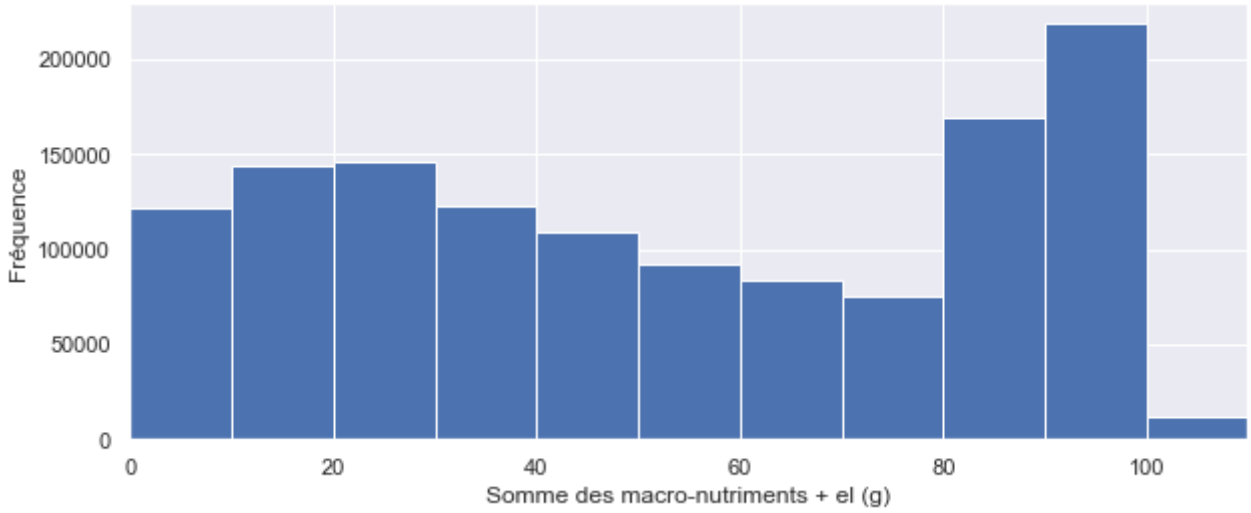

In [32]:
```
nutritional_values_df = nutritional_values_df.loc[nutritional_values_df.g_sum <= 102 ].copy()

if print_details :
    compare_two_related_columns(nutritional_values_df, ['g_sum', 'salt_100g'],
                                (1,0, {'color' : 'red'}), MAX_G, marker = ".", alpha = 0.1, fig
    compare_two_related_columns(nutritional_values_df, ['g_sum', 'carbohydrates_100g'],
                                (1,0, {'color' : 'red'}), MAX_G, marker = ".", alpha = 0.1, fig
    compare_two_related_columns(nutritional_values_df, ['g_sum', 'fat_100g'],
                                (1,0, {'color' : 'red'}), MAX_G, marker = ".", alpha = 0.1, fig
    compare_two_related_columns(nutritional_values_df, ['g_sum', 'proteins_100g'],
                                (1,0, {'color' : 'red'}), MAX_G, marker = ".", alpha = 0.1, fig
```

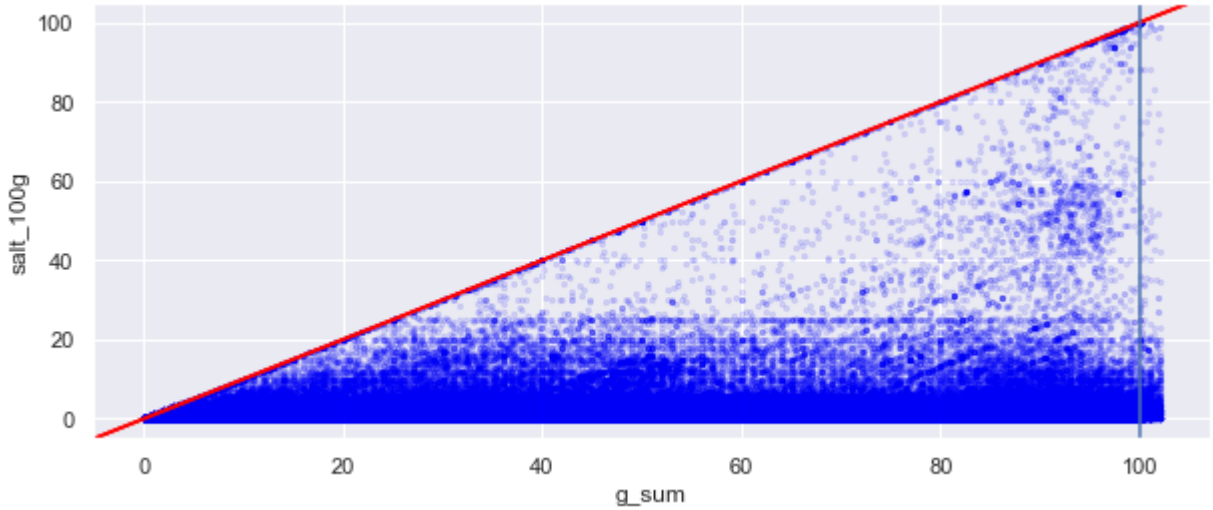

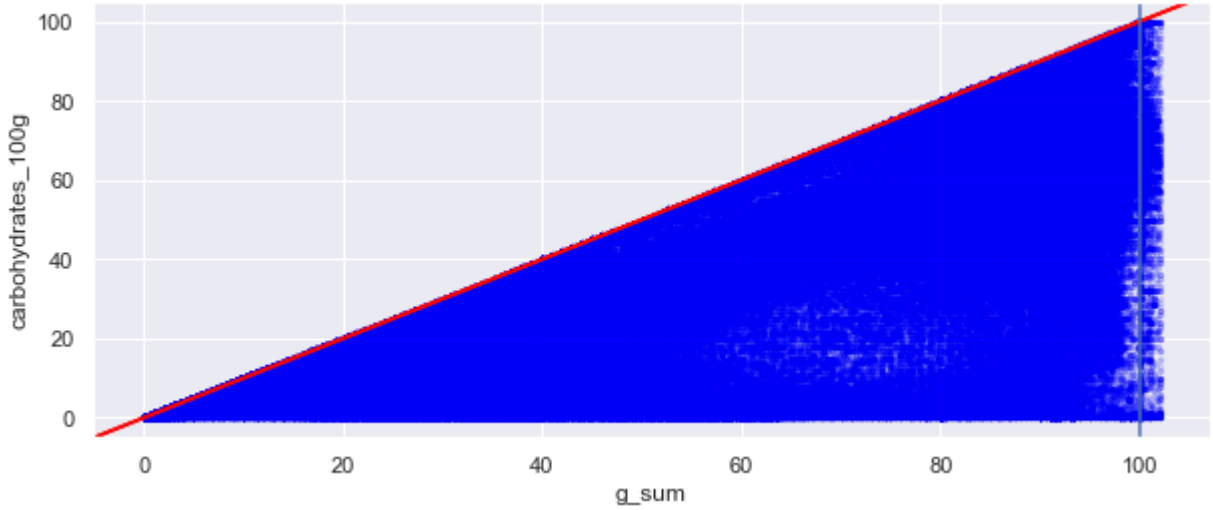

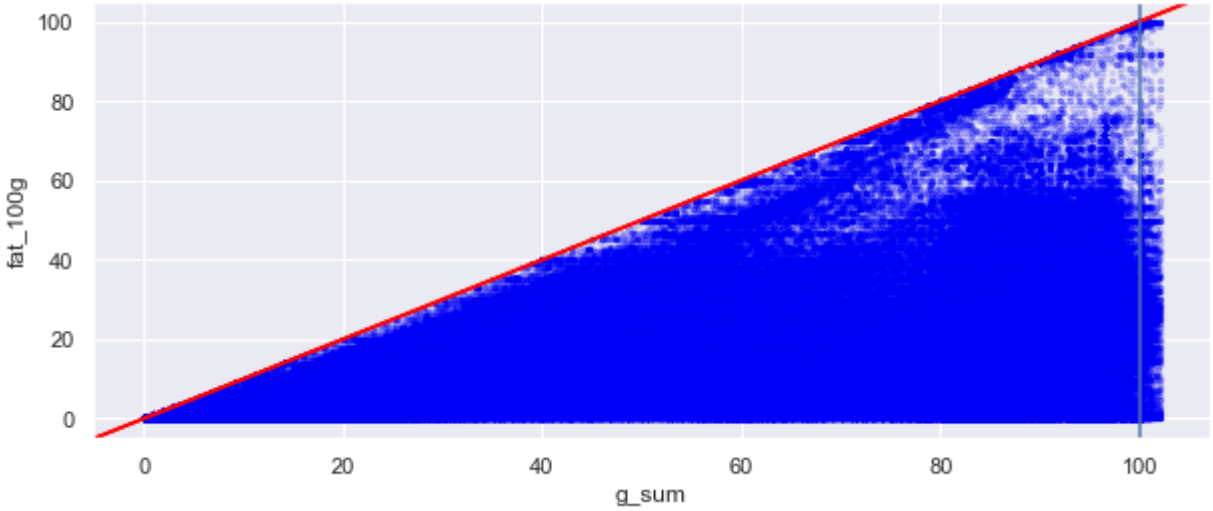

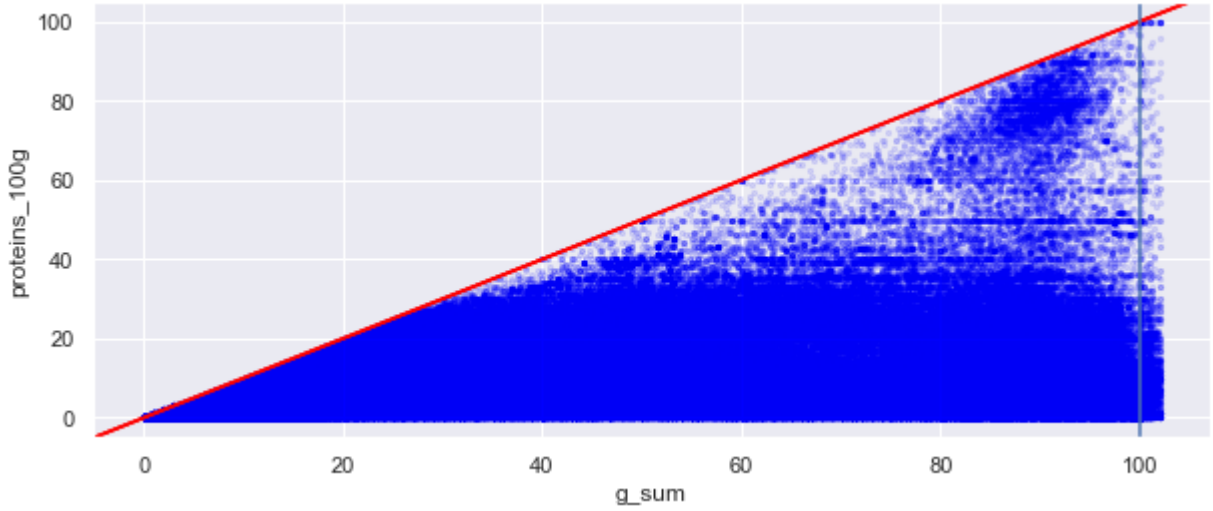

L'énergie nutrionelle venant des macro-nutriments

On va estimer la partie de l'énergie nutritionelle ventant des macro-nutriments (matières grasses, glucides et protéins). On peut penser que cette énergie computée représente l'énergie nutritionelle minimum d'un produit, car un produit peut contenir des autres nutriments qui contribuent à l'énergie nutitionelle qui ne font pas néceassairement partie des macro-nutriments, comme les alcools et les fibres alimentaires. Cette notion est une piège: les polyols y inclut l'erythriol sont contient dans les glycides, mais ils ont une valeur énergique plus bas que des autres glucides (10 kJ et 0 kJ au lieu de 17 kJ). De plus ce ne sont pas simplement des additifs. Il y a des produits comme les chewing-gums, qui peuvent avoir un taux de polyols plus que 80%. On note aussi qu'on peut achète l'erythriol pur en pudre. C'est utilisé comme le sucre.

Il faut aussi tenir compte que les conversions des quantitiés de nutriments en énergie nutritionelle sont fait avec des tableaux de conversation simplifiés. Les conversions entre kJ et kcal peuvent aussi introduire des erreures. C'est surtout le cas pour les différents types de glucides. (Fructose : 15.4 kJ, Glucose : 15.8 kJ, Succrose (grannulé) : 16.2 kJ, ... si on regarde spécifiquement ces sucres).

On doit aussi noté que les réglementations ou conventions sur ce que est inclue dans la table nutritionnelle peut varier entre les différents pays. Par example, aux Etat-Unis, les fibres alimentaires sont inclus dans les glucides, mais en UE ils ne le sont pas. Les fibres alimentaires est aussi un example où la définition peut varier un peu entre les différents pays.

Pour avoir une idéé comment les différents nutriments contribuent à l'énergie, on va les tracer contre l'énergie renseignée.

Eliminer les valeurs qui sont en dehors bornes raissonables:

Après, on va les éléments pour lesquels les quantités des nutriments ne sont pas cohérentes avec l'énergie nutitionelle renseignée. Pour les différents nutriments on donne une plague d'énergie nutitionelle qu'ils peuvent avoir.

Les plagues d'énergie pour les nutriments

- Les glucides: 0 - 18.7 kJ
  - Les sucres : 15.3 - 18.7 kJ
  - Les autre glucides (= non-sucres) : 0 - 18.7 kJ
- La matière grasse : 36.2 - 37.8 kJ
- Les protéins : 16.5 - 17.5 kJ
- Le "reste" (ce que ne fait pas partie des nutriments en haute) : 0 - 37.8 kJ

Les régles d'élimination supplémentaires

- La minimum énergie totale est : 36.2 *matière grasse* + *16.5* protéins + 15.3 kJ * sucres <= énergie totale renseignée (<= 3780 kJ)
- La maximum énergie totale est : 37.8 *matière grasse* + *17.5* protéins + 18.7 kJ *glucides* + *37.8* "reste" >= énergie totale renseignée (>= 0 kJ)

- La maximum énergie du "reste" : énergie totale renseignée - minimum énergie totale >= 0 kJ

- La minimum énergie du "reste" : énergie totale renseignée - 37.8 *matière grasse* + *17.5* protéins + 18.7 kJ *glucides* <= *37.80* "reste"

In [33]:
```
nutritional_values_df['others_100g'] = 100 - nutritional_values_df.g_sum
nutritional_values_df['othercarbs_100g'] = nutritional_values_df.carbohydrates_100g - nutritior

nutritional_values_df['energy_min_computed'] = 36.2 * nutritional_values_df.fat_100g \
                                        + 15.3 * nutritional_values_df.sugars_100g \
                                        + 16.5 * nutritional_values_df.proteins_100g
nutritional_values_df['energy_max_computed'] = 37.8 * nutritional_values_df.fat_100g \
                                        + 18.7 * nutritional_values_df.carbohydrates_100g \
```

```
                                        + 17.5 * nutritional_values_df.proteins_100g \
                                        + 37.8 * nutritional_values_df.others_100g

nutritional_values_df['energy_others_max'] = nutritional_values_df.energy_100g - nutritional_va
nutritional_values_df['energy_others_min'] = nutritional_values_df.energy_100g - 37.8 * nutriti
                                                - 18.7 * nutritional_values_df.carbohydrates_10
                                                - 17.5 * nutritional_values_df.proteins_100g
```

In [34]:

```
energy_sugar_mismatch = np.array([True if i > j / 15.3 or i > (3780 - j) / (37.8-18.7)  else Fa
                                        nutritional_values_df.sugars_100g,
                                        nutritional_values_df.energy_100g)])

energy_fat_mismatch = nutritional_values_df.fat_100g.values > nutritional_values_df.energy_100g

energy_proteins_mismatch = np.array([True if i > j / 16.5 or i > (3780 - j) / (37.8-17.5)  else
                                        nutritional_values_df.proteins_100g,
                                        nutritional_values_df.energy_100g)])

energy_carbs_mismatch = nutritional_values_df.carbohydrates_100g.values > \
                        (3780 - nutritional_values_df.energy_100g.values) / (37.8-18.7)
energy_othercarbs_mismatch = nutritional_values_df.othercarbs_100g.values > \
                                (3780 - nutritional_values_df.energy_100g.values) / (37.8-18.7)

energy_toolow = nutritional_values_df.energy_100g.values < nutritional_values_df.energy_min_com
energy_toohigh = nutritional_values_df.energy_100g.values > nutritional_values_df.energy_max_co

energy_others_toolow =  nutritional_values_df.energy_others_max.values < 0
energy_others_toohigh = nutritional_values_df.energy_others_min.values > 37.8 * nutritional_val

select = ~(energy_sugar_mismatch | energy_fat_mismatch | energy_proteins_mismatch | \
           energy_carbs_mismatch | energy_othercarbs_mismatch | \
           energy_toolow  | energy_toohigh | \
           energy_others_toolow | energy_others_toohigh )
```

In [35]:

```
pd.Series(select).value_counts()#/pd.Series(select).value_counts().sum()
```

Out[35]:

```
True     1233924
False      55984
dtype: int64
```

In [36]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'carbohydrates_100g'
                            [(1/15.3, 0, {'color' : 'red', 'linewidth' : 2}),
                             (-1/(37.8-18.7), 3780/(37.8-18.7), {'color' : 'red', 'linewidth' :
                             (1/10, 0, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'}),
                             (1/4.2, 0, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'}),
                             (1/1.6, 0, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'}),
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

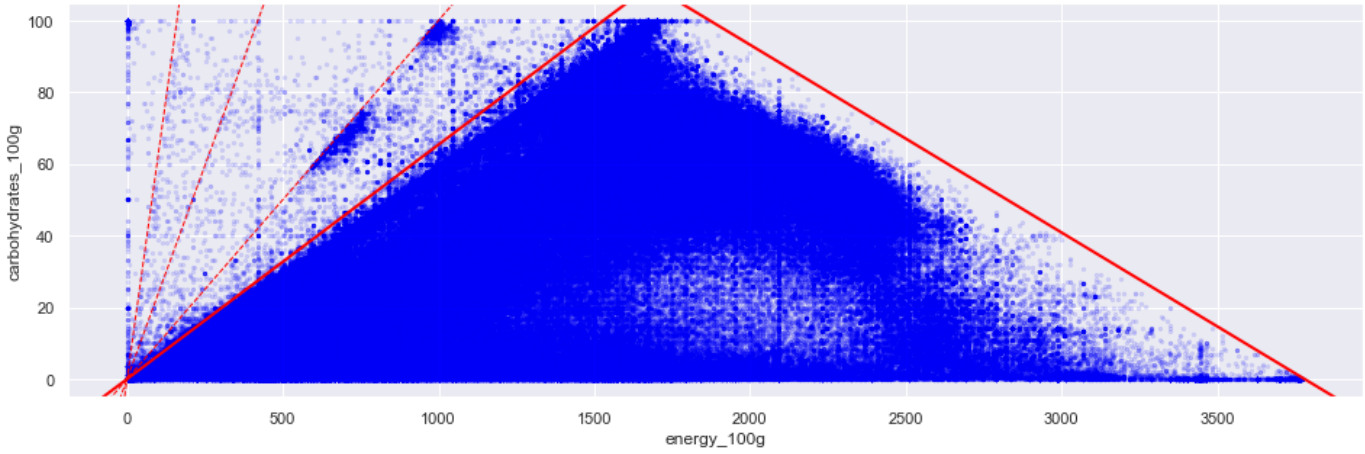

In [37]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'sugars_100g'],
                            [(1/15.3, 0, {'color' : 'red', 'linewidth' : 2}),
```

```
                                (-1/(37.8-18.7), 3780/(37.8-18.7), {'color' : 'red', 'linewidth' :
                                marker = ".", alpha = 0.1, figsize = (16,5))
```

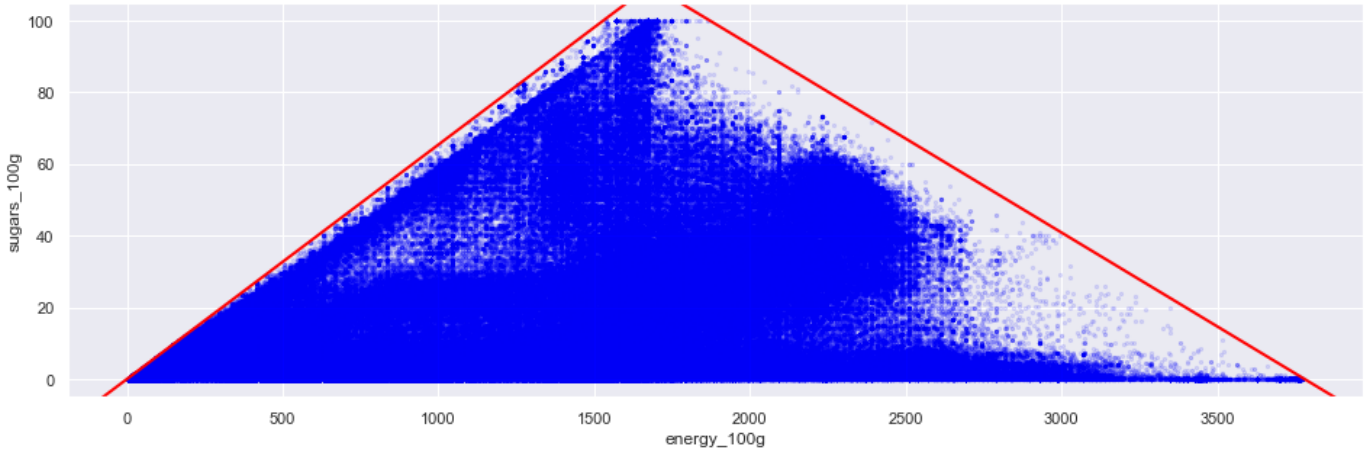

In [38]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'othercarbs_100g'],
                            [(1/16.5, 0, {'color' : 'red', 'linewidth' : 2}),
                             (-1/(37.8-17.5), 3780/(37.8-17.5) , {'color' : 'red', 'linewidth'
                             (1/10, 0, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'})]
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

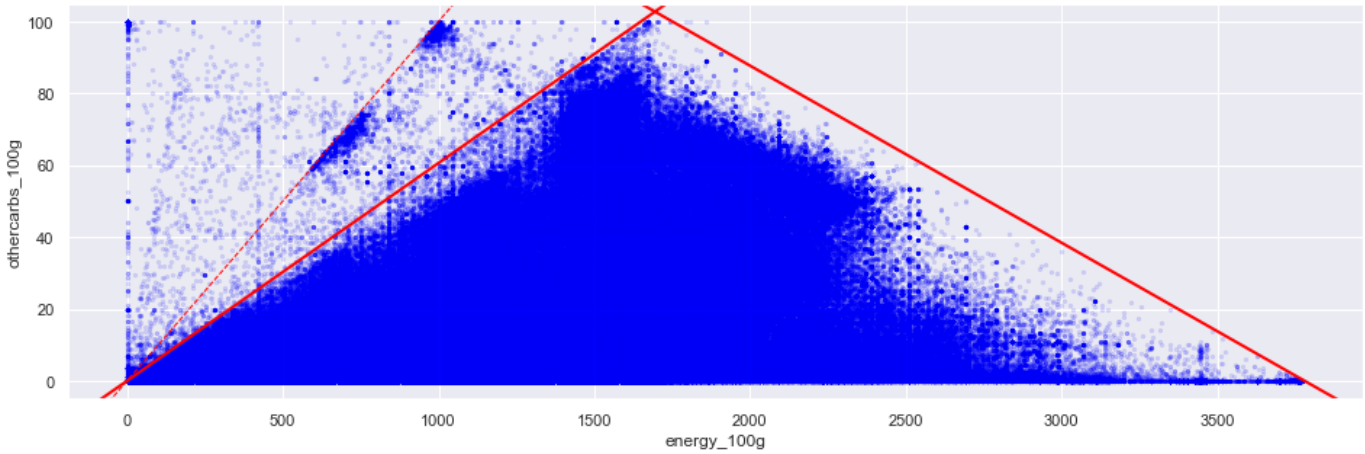

In [39]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'fat_100g'],
                            [(1/36.2, 0, {'color' : 'red', 'linewidth' : 2})],
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

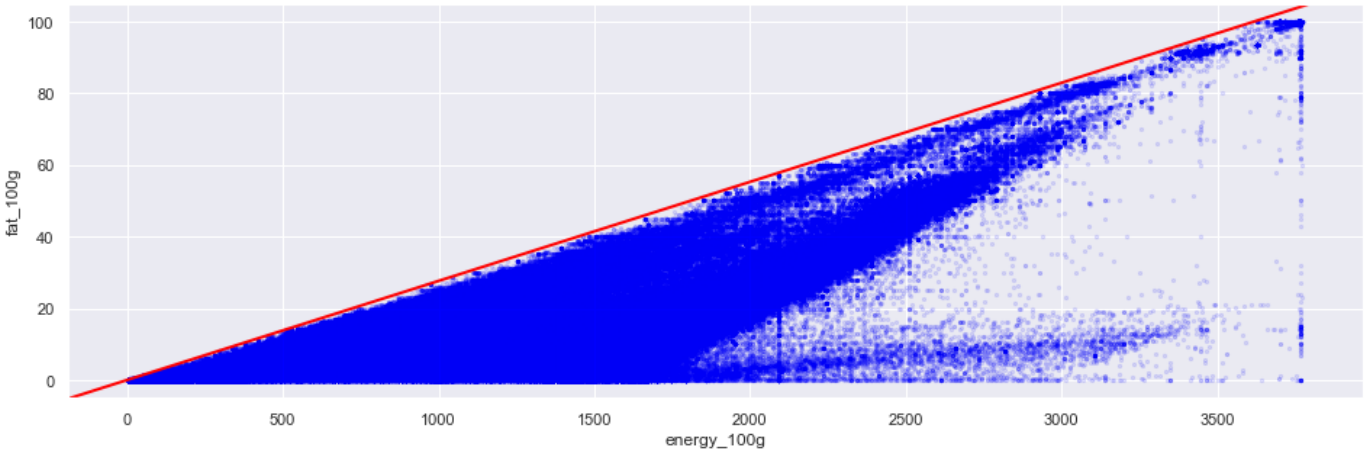

In [40]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'proteins_100g'],
                            [(1/16.5, 0, {'color' : 'red', 'linewidth' : 2}),
                             (-1/(37.8-17.5), 3780/(37.8-17.5) , {'color' : 'red', 'linewidth'
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

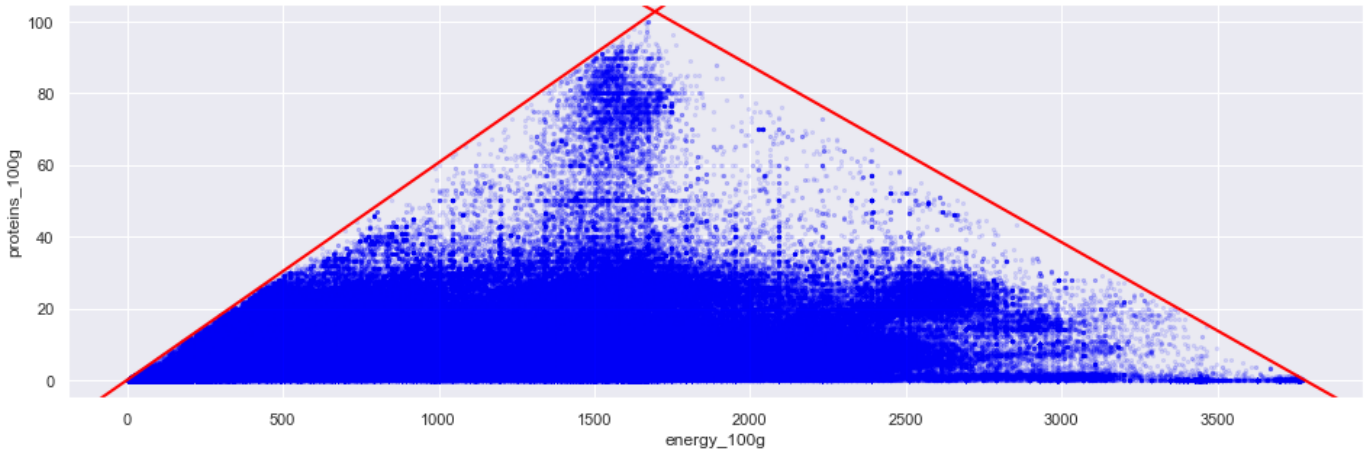

In [41]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'others_100g'],
                            [(-1/37.8, 100, {'color' : 'red', 'linewidth' : 2}),
                             (-1/13, 100, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'
                             (-1/17, 100, {'color' : 'red', 'linewidth' : 2}),
                             (-1/10, 100, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'
                             (-1/(2*37.8), 100, {'color' : 'red', 'linewidth' : 2}),
                            (-1/(37.8-25), 3780/(37.8-25), {'color' : 'red', 'linewidth' : 2})]
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

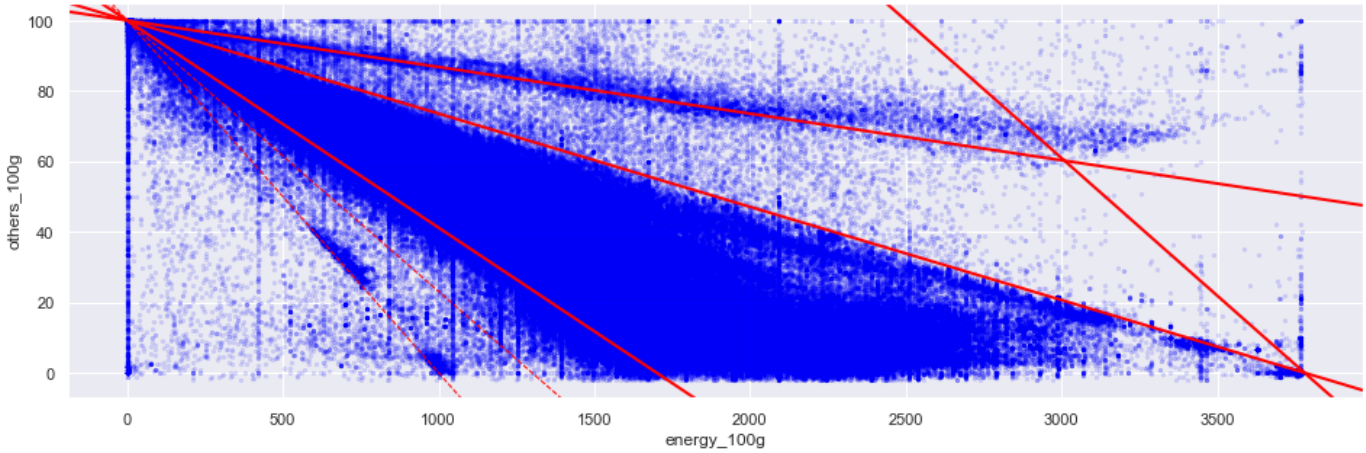

In [42]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'energy_max_computed
                            [(1, 0, {'color' : 'red', 'linewidth' : 2}),
                             (-1.7, 3780, {'color' : 'green', 'linewidth' : 2, 'linestyle' : '-
                            [(1870, {'color':'green'}),(3780,{'color':'green'})],
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

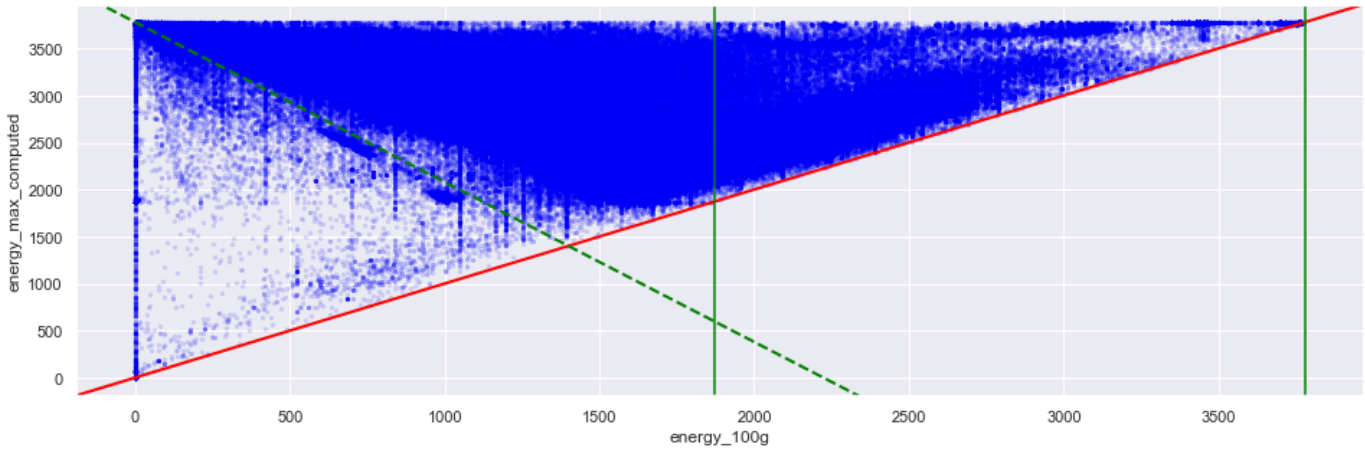

In [43]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'energy_min_computed
                            [(1, 0, {'color' : 'red', 'linewidth' : 2}),
                             (1/4.2, 0, {'color' : 'green', 'linewidth' : 2, 'linestyle' : '--'
                            [(1870, {'color':'green'}),(3780,{'color':'green'})],
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

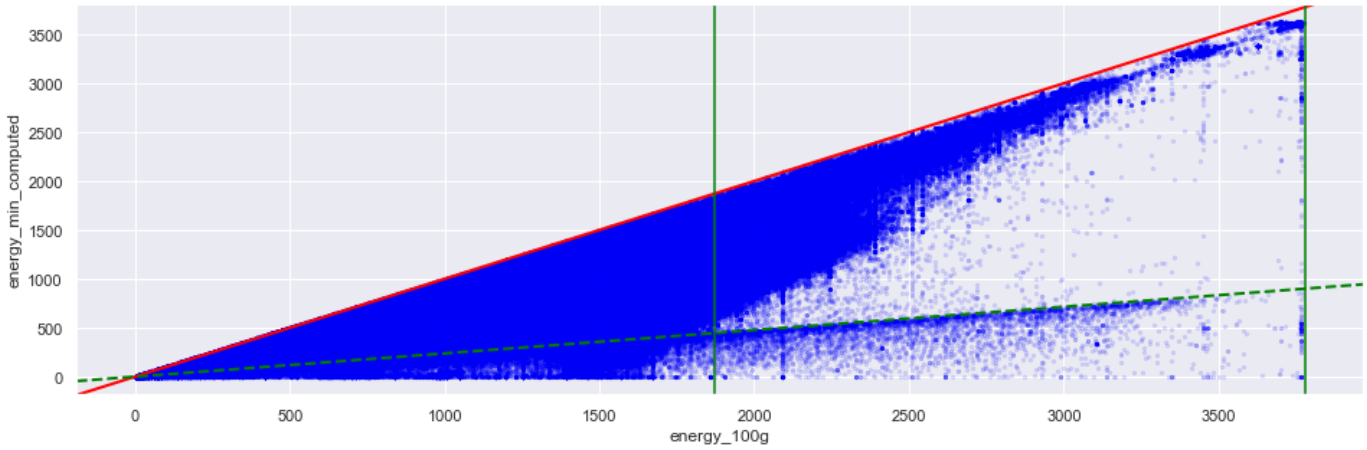

In [44]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'energy_others_max']
                            [(0, 0, {'color' : 'red', 'linewidth' : 2, 'linestyle' : '-'}),
                             (1, -3780, {'color' : 'red', 'linewidth' : 1, 'linestyle' : '--'})
                             (1, 0, {'color' : 'green', 'linewidth' : 1, 'linestyle' : '--'})],
                            [(3780, {'color':'green'})],
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

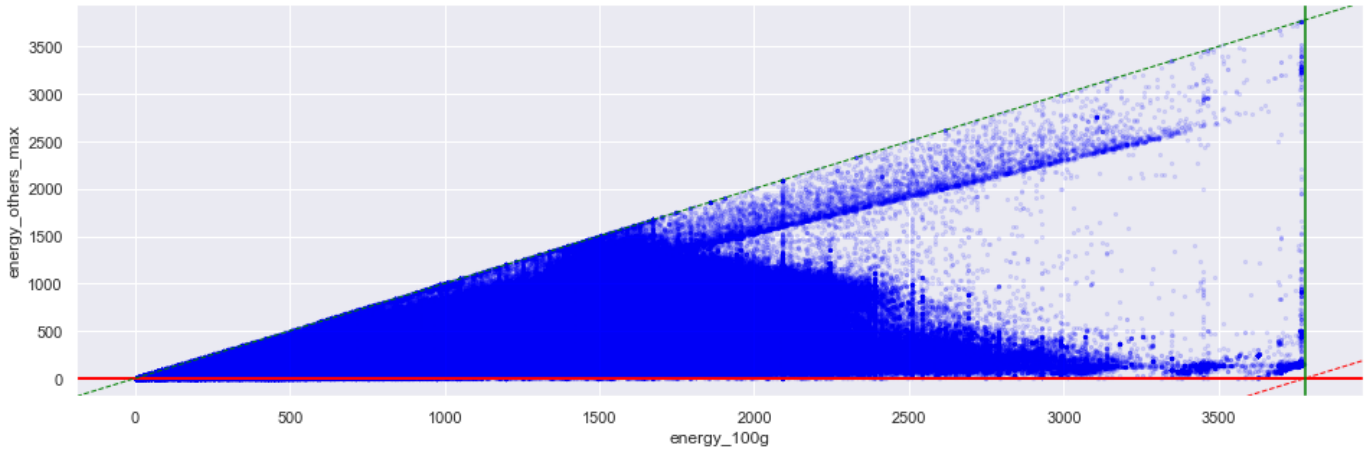

In [45]:

```
compare_two_related_columns(nutritional_values_df[select], ['energy_100g', 'energy_others_min']
                            [(0, 0, {'color' : 'green', 'linewidth' : 1, 'linestyle' : '--'}),
                             (1, -3780, {'color' : 'green', 'linewidth' : 1, 'linestyle' : '--'
                             (1, 0, {'color' : 'red', 'linewidth' : 2, 'linestyle' : '-'}),
                             (1/1.33, 0, {'color' : 'orange', 'linewidth' : 1, 'linestyle' : '-
                            [(3780, {'color':'green'})],
                             marker = ".", alpha = 0.1, figsize = (16,5))
```

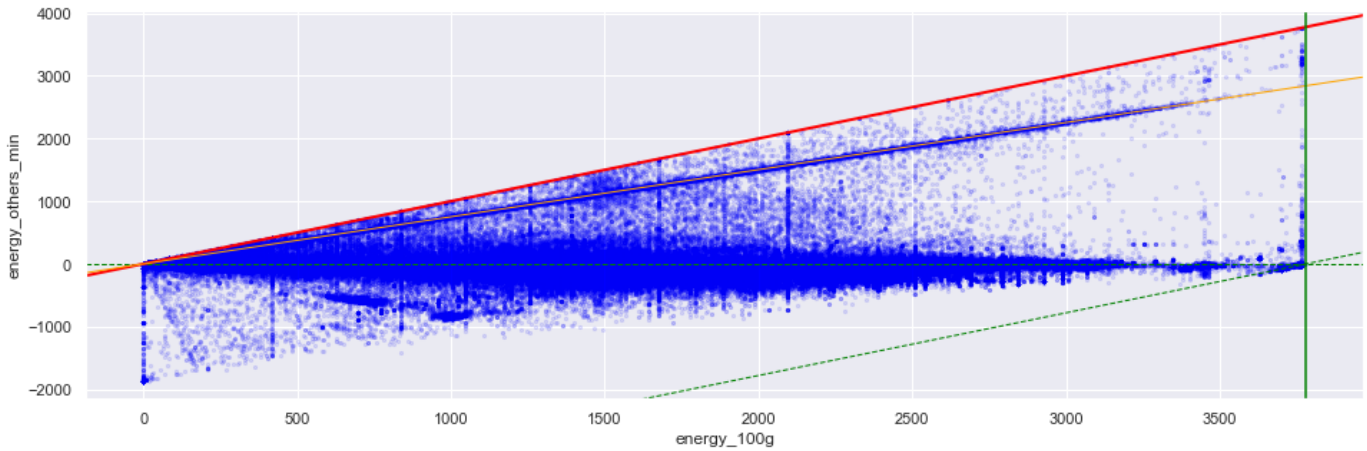

In [46]:

```
nutritional_values_df = nutritional_values_df[select].copy()
```

In [47]:

```
#look at the distribution of the data among the pnns-groups
if print_details :
```

```
    openfoodfacts_df.loc[nutritional_values_df.index]["pnns_groups_1"].value_counts() / \
        openfoodfacts_df.loc[nutritional_values_df.index]["pnns_groups_1"].value_counts().sum()
```

3.4.3 Les classements et scores d'alimentation (déjà mis en oeuvre)

Finalement, on va regarder le taux de remplissages des scores (NutriScore, Ecoscore) et des classements (Novagroup) des alimentation qui sont déjà mis en oeuvre pour aider les consommateurs à faire leur choix.

In [48]:
```
food_scores = ['nutriscore_score', 'nutriscore_grade','nutrition_score_fr_100g', 'nutrition_sco
               'nova_group','ecoscore_score_fr', 'ecoscore_grade_fr' ]
```

In [49]:
```
openfoodfacts_df[food_scores].count()
```

Out[49]:
```
nutriscore_score           698857
nutriscore_grade           698857
nutrition_score_fr_100g    698862
nutrition_score_uk_100g         9
nova_group                 618599
ecoscore_score_fr          460726
ecoscore_grade_fr          460726
dtype: int64
```

In [50]:
```
food_scores = ['nutriscore_score', 'nutriscore_grade','nutrition_score_fr_100g',
               'nova_group','ecoscore_score_fr', 'ecoscore_grade_fr' ]
compare_column_completeness(openfoodfacts_df, food_scores)
```

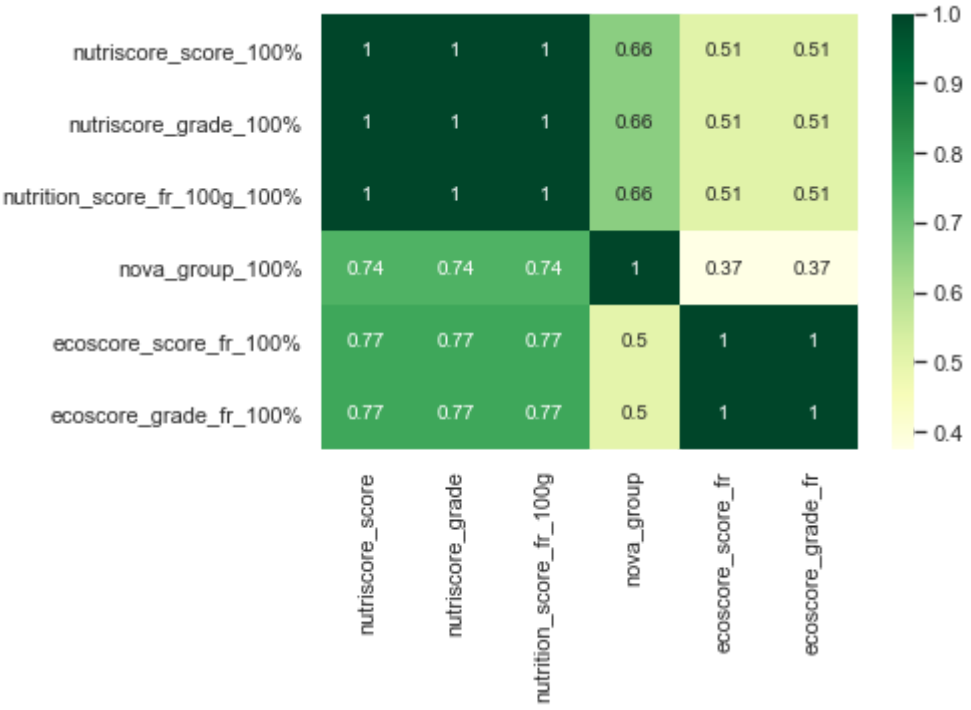

Le Nutri-Score

On va essayer d'éliminer des valeurs erronées. Les scores du NutriScore donne des classements suivants:

Score / Points		Classement
Aliments solides	**Boissons**	
-15 à -1	Eaux	A
0 à 2	-15 à 1	B
3 à 10	2 à 5	C
11 à 18	6 à 9	D
19 à 40	10 à 40	E

On va utiliser le groupes PNNS pour aider à faire les régles d'élimination. On va suivre le tableau en haute pour les boissons et les soilides (= les non-'known' et non-boissons). Pour les 'unknown' on va donner les bornes le plus large entre les solides et boissons.

Les 'unknown' :

- Pour A : score <= 1
- Pour B : score <= 1
- Pour C : 2 <= score <= 10
- Pour D : 6 <= score <= 18
- Pour E : 10 <= score

In [51]:
```
#check if nutriscore_score and nutriscore_score_fr_100g are the same. they are
(openfoodfacts_df['nutriscore_score'] - openfoodfacts_df['nutrition_score_fr_100g']).value_cour
```

Out[51]:
```
0.0    698857
dtype: int64
```

In [52]:
```
openfoodfacts_df.nutriscore_grade.unique()
```

Out[52]:
```
array([nan, 'd', 'b', 'a', 'c', 'e'], dtype=object)
```

In [53]:
```
openfoodfacts_df[openfoodfacts_df.pnns_groups_1 != 'unknown'].nutriscore_grade.sort_values().va
```

Out[53]:
```
583498
```

In [54]:
```
nutriscore_values = ['nutriscore_score', 'nutriscore_grade', 'pnns_groups_1', 'pnns_groups_2']
```

In [55]:
```
nutriscore_values_df = openfoodfacts_df[nutriscore_values].copy()
```

In [56]:
```
is_empty = np.where(nutriscore_values_df.isnull().sum(axis=1) >= 1, True, False)

pd.Series(~is_empty).value_counts()/pd.Series(~is_empty).value_counts().sum()
```

Out[56]:
```
False    0.633592
True     0.366408
dtype: float64
```

In [57]:
```
nutriscore_values_df = nutriscore_values_df.loc[~is_empty].copy()
```

In [58]:
```
is_beverage = nutriscore_values_df.pnns_groups_1 == 'Beverages'
is_unknown = nutriscore_values_df.pnns_groups_1 == 'unknown'
is_food = ~(is_beverage | is_unknown)
```

```
is_water = nutriscore_values_df.pnns_groups_2 == 'Waters and flavored waters'

is_catA = nutriscore_values_df.nutriscore_grade == 'a'
is_catB = nutriscore_values_df.nutriscore_grade == 'b'
is_catC = nutriscore_values_df.nutriscore_grade == 'c'
is_catD = nutriscore_values_df.nutriscore_grade == 'd'
is_catE = nutriscore_values_df.nutriscore_grade == 'e'


catA_beverage_mismatch = (is_beverage & is_catA) & ( ~is_water | \
                                                    (nutriscore_values_df.nutriscore_score > 1)
                                                    (nutriscore_values_df.nutriscore_score < -1
catB_beverage_mismatch = (is_beverage & is_catB) & ((nutriscore_values_df.nutriscore_score > 1)
                                                    (nutriscore_values_df.nutriscore_score < -1
catC_beverage_mismatch = (is_beverage & is_catC) & ((nutriscore_values_df.nutriscore_score > 5)
                                                    (nutriscore_values_df.nutriscore_score < 2)
catD_beverage_mismatch = (is_beverage & is_catD) & ((nutriscore_values_df.nutriscore_score > 9)
                                                    (nutriscore_values_df.nutriscore_score < 6)
catE_beverage_mismatch = (is_beverage & is_catE) & ((nutriscore_values_df.nutriscore_score > 40
                                                    (nutriscore_values_df.nutriscore_score < 10

beverage_score_mismatch = catA_beverage_mismatch | catB_beverage_mismatch | catC_beverage_misma
                          catD_beverage_mismatch | catE_beverage_mismatch


catA_food_mismatch = (is_food & is_catA) & ((nutriscore_values_df.nutriscore_score > -1) | \
                                            (nutriscore_values_df.nutriscore_score < -15))
catB_food_mismatch = (is_food & is_catB) & ((nutriscore_values_df.nutriscore_score > 2) | \
                                            (nutriscore_values_df.nutriscore_score < 0))
catC_food_mismatch = (is_food & is_catC) & ((nutriscore_values_df.nutriscore_score > 10) | \
                                            (nutriscore_values_df.nutriscore_score < 3))
catD_food_mismatch = (is_food & is_catD) & ((nutriscore_values_df.nutriscore_score > 18) | \
                                            (nutriscore_values_df.nutriscore_score < 11))
catE_food_mismatch = (is_food & is_catE) & ((nutriscore_values_df.nutriscore_score > 40) | \
                                            (nutriscore_values_df.nutriscore_score < 19))

food_score_mismatch = catA_food_mismatch | catB_food_mismatch | catC_food_mismatch | \
                      catD_food_mismatch | catE_food_mismatch


catA_unknown_mismatch = (is_unknown & is_catA) & ((nutriscore_values_df.nutriscore_score > 1) |
                                                  (nutriscore_values_df.nutriscore_score < -15)
catB_unknown_mismatch = (is_unknown & is_catB) & ((nutriscore_values_df.nutriscore_score > 1) |
                                                  (nutriscore_values_df.nutriscore_score < -15)
catC_unknown_mismatch = (is_unknown & is_catC) & ((nutriscore_values_df.nutriscore_score > 10)
                                                  (nutriscore_values_df.nutriscore_score < 2))
catD_unknown_mismatch = (is_unknown & is_catD) & ((nutriscore_values_df.nutriscore_score > 18)
                                                  (nutriscore_values_df.nutriscore_score < 6))
catE_unknown_mismatch = (is_unknown & is_catE) & ((nutriscore_values_df.nutriscore_score > 40)
                                                  (nutriscore_values_df.nutriscore_score < 10))

unknown_score_mismatch = catA_unknown_mismatch | catB_unknown_mismatch | catC_unknown_mismatch
                         catD_unknown_mismatch | catE_unknown_mismatch

select = ~(food_score_mismatch | beverage_score_mismatch | unknown_score_mismatch)
```

In [59]:

```
if print_details :
    print("The NutriScores that are mismatched :\n")
    print("Unknowns :")
    print(unknown_score_mismatch[nutriscore_values_df[is_unknown].index].value_counts())
    print()
    print("Food :")
    print(food_score_mismatch[nutriscore_values_df[is_food].index].value_counts())
    print()
    print("Beverages :")
    print(beverage_score_mismatch[nutriscore_values_df[is_beverage].index].value_counts())
```

```
The NutriScores that are mismatched :
```

```
Unknowns :
False    111064
True       4295
dtype: int64

Food :
False    539444
True        403
dtype: int64

Beverages :
False    40486
True      3165
dtype: int64
```

In [60]:
```
select.value_counts()/select.value_counts().sum()
```

Out[60]:
```
True     0.988749
False    0.011251
dtype: float64
```

In [61]:
```
nutriscore_values_df = nutriscore_values_df.loc[select].copy()
```

Les NOVA catégories

Les NOVA catégories sont une façon de classer les produits d'alimentation en fonction de leurs ingrédients (nombre, type et degrée de transformation). On va transformer les valeurs en string et donner la catégorie 'unknown' au valeurs vides.

In [62]:
```
openfoodfacts_df = openfoodfacts_df.astype({'nova_group' : 'string'})
openfoodfacts_df['nova_group'].describe()
```

Out[62]:
```
count     618599
unique         4
top          4.0
freq      411446
Name: nova_group, dtype: object
```

In [63]:
```
openfoodfacts_df.replace(to_replace={'nova_group' : {np.nan:'unknown'}}, inplace = True)
openfoodfacts_df[openfoodfacts_df.nova_group != 'unknown']['nova_group'].value_counts(normalize
```

Out[63]:
```
4.0    0.665126
3.0    0.206835
1.0    0.108886
2.0    0.019153
Name: nova_group, dtype: float64
```

L'eco-score

On va reagarder le taux de remplissage et la rélation entre score et classement du eco-score (ecoscore_score_fr, ecoscore_grade_fr).

In [64]:
```
openfoodfacts_df[['ecoscore_grade_fr','ecoscore_score_fr']].value_counts().sum()#/num_inds
```

Out[64]:
```
460726
```

In [65]:
```
openfoodfacts_df[openfoodfacts_df.ecoscore_grade_fr == 'a'].ecoscore_score_fr.sort_values().val
```

Out[65]:
```
80.0     1008
81.0      871
82.0      895
```

```
83.0      810
84.0     1152
85.0     1035
86.0      361
87.0      651
88.0      790
89.0      818
90.0      685
91.0     1035
92.0      462
93.0      585
94.0      651
95.0      404
96.0      278
97.0      367
98.0      227
99.0      673
100.0     335
101.0     150
102.0     141
103.0     227
104.0     406
105.0     262
106.0     294
107.0     221
108.0     213
109.0     343
110.0      89
111.0      57
112.0     105
113.0     104
114.0      96
115.0     101
116.0     116
117.0      69
118.0      63
119.0      62
120.0      48
121.0     105
122.0      78
123.0      46
124.0      65
125.0      26
Name: ecoscore_score_fr, dtype: int64
```

In [66]:
```
openfoodfacts_df['ecoscore_grade_fr'].value_counts(normalize = True)
```

Out[66]:
```
d    0.334713
b    0.268437
e    0.181594
c    0.177099
a    0.038157
Name: ecoscore_grade_fr, dtype: float64
```

In [67]:
```
ecoscore_values_df = openfoodfacts_df[['ecoscore_score_fr','ecoscore_grade_fr']].dropna()
```

3.4.4 Le code à barré

In [68]:
```
#information on the product codes
openfoodfacts_df[openfoodfacts_df.astype('string').duplicated('code', keep = False)]['code'].as
```

Out[68]:
```
4565                    1
497163                  1
90493                   4
339661                  4
4566                   10
                 ...
1829702     8711200350377
484105      8716671000172
```

```
1842653     8716671000172
687122     30383354190402
687123     30383354190402
Name: code, Length: 1846, dtype: int64
```

In [69]:

```
openfoodfacts_df['code'] = openfoodfacts_df['code'].astype('string')
max_code_len = openfoodfacts_df['code'].map(len).max()

code_is_duplicated = openfoodfacts_df['code'].str.zfill(max_code_len).duplicated(keep = False)
ind_vals = openfoodfacts_df[code_is_duplicated]['code'].str.lstrip('0').sort_values(ascending =
#.sort_values(ascending=False).head(50)#.index.values
#ind_vals
openfoodfacts_df.iloc[ind_vals[-20:],:]#.notna().sum(axis = 1)
```

Out[69]:

	code	url	creator	created_t	created_datetime	last_m
770	00001002	http://world-en.openfoodfacts.org/product/0000...	kiliweb	1601626294	2020-10-02T08:11:34Z	162
497744	1002	http://world-en.openfoodfacts.org/product/1002...	prepperapp	1585141405	2020-03-25T13:03:25Z	158
279812	01002	http://world-en.openfoodfacts.org/product/0100...	prepperapp	1585139969	2020-03-25T12:39:29Z	158
279806	010011	http://world-en.openfoodfacts.org/product/0100...	halal-app-chakib	1586238266	2020-04-07T05:44:26Z	158
497676	10011	http://world-en.openfoodfacts.org/product/1001...	openfoodfacts-contributors	1619588369	2021-04-28T05:39:29Z	161
497648	1001	http://world-en.openfoodfacts.org/product/1001...	prepperapp	1585141464	2020-03-25T13:04:24Z	162
279805	01001	http://world-en.openfoodfacts.org/product/0100...	kiliweb	1581790061	2020-02-15T18:07:41Z	158
18	0000000001001	http://world-en.openfoodfacts.org/product/0000...	openfoodfacts-contributors	1537766416	2018-09-24T05:20:16Z	153
5	0000000000100	http://world-en.openfoodfacts.org/product/0000...	del51	1444572561	2015-10-11T14:09:21Z	144
497165	100	http://world-en.openfoodfacts.org/product/100/...	openfoodfacts-contributors	1536886069	2018-09-14T00:47:49Z	156
497164	10	http://world-en.openfoodfacts.org/product/10/b...	date-limite-app	1568615169	2019-09-16T06:26:09Z	156
4566	10	http://world-en.openfoodfacts.org/product/0010...	foodvisor	1561728156	2019-06-28T13:22:36Z	162
279751	010	http://world-en.openfoodfacts.org/product/010/...	rigione	1541543350	2018-11-06T22:29:10Z	154
769	000010	http://world-en.openfoodfacts.org/product/0000...	jeanbono	1476947941	2016-10-20T07:19:01Z	162
317	00000001	http://world-en.openfoodfacts.org/product/0000...	kiliweb	1592775003	2020-06-21T21:30:03Z	161
4565	1	http://world-en.openfoodfacts.org/product/001/...	openfoodfacts-contributors	1547401452	2019-01-13T17:44:12Z	158
1432	0001	http://world-en.openfoodfacts.org/product/0001...	date-limite-app	1531760498	2018-07-16T17:01:38Z	157
497163	1	http://world-en.openfoodfacts.org/product/1/me...	date-limite-app	1575964823	2019-12-10T08:00:23Z	159

	code	url	creator	created_t	created_datetime	last_m
279750	01	http://world-en.openfoodfacts.org/product/01/s...	usda-ndb-import	1489090388	2017-03-09T20:13:08Z	158
768	00001	http://world-en.openfoodfacts.org/product/00001	elcoco	1572434354	2019-10-30T11:19:14Z	157

20 rows × 186 columns

3.5 Les Exports

On va exporter les données pertinentes et nettoyées pour pouvoir les importer et traiter dans le fichier 'exploration'.

In [70]:
```
if save_data:
    food_groups = ['pnns_groups_1','pnns_groups_2','nova_group']
    openfoodfacts_df[food_groups].to_csv(os.getcwd() + '\\Data\\' + "openfoodfacts_food_groups'
    nutritional_values_df.to_csv(os.getcwd() + '\\Data\\' + "openfoodfacts_nutritional_values")
    nutriscore_values_df.to_csv(os.getcwd() + '\\Data\\' + "openfoodfacts_nutriscore")
    ecoscore_values_df.to_csv(os.getcwd() + '\\Data\\' + "openfoodfacts_ecoscore")
    food_info = ['code','product_name','url']
    openfoodfacts_df[food_info].to_csv(os.getcwd() + '\\Data\\' + "openfoodfacts_food_info")
```

4. Conclusions

4.1 Les catégories alimentaires

- **Les catégories PNNS vont ensemble** (pnns_groups_1 et pnns_groups_2): à l'exception de deux éléments, soit toutes les deux categories sont reseignées soit toutes les deux sont inconnues (= 'unknown').
- **38.4% des catégories PNNS sont renseignées.** Les éléments non-renseignés font partie du groupe 'unknown' = inconnu.

- **10 (+1) catégories principales** (pnns_groups_1)
- **39 (+1) sous-catégories** (pnns_groups_2)

La structure des catégories PNNS:

- unknown
  - unknown
- Fruits and vegetables
  - Fruits
  - Dried fruits
  - Vegetables
  - Soups
- Cereals and potatoes
  - Bread
  - Cereals
  - Breakfast cereals
  - Potatoes
  - Legumes
- Milk and dairy products
  - 'Milk and yogurt'

    - 'Cheese'
    - 'Dairy desserts'
    - 'Ice Cream'
- Fish Meat Eggs
    - 'Meat'
    - 'Processed meat'
    - 'Offals'
    - 'Fish and seafood'
    - 'Eggs'
- Fat and sauces
    - 'Dressings and sauces'
    - 'Fats'
- Salty snacks
    - 'Appetizers'
    - 'Nuts'
    - 'Salty and fatty products'
- Sugary snacks
    - 'Pastries'
    - 'Biscuits and cakes'
    - 'Chocolate products'
    - 'Sweets'
- Composite foods
    - 'One-dish meals'
    - 'Pizza pies and quiches'
    - 'Sandwiches'
- Beverages
    - 'Sweetened beverages'
    - 'Artificially sweetened beverages'
    - 'Unsweetened beverages'
    - 'Fruit juices'
    - 'Plant-based milk substitutes'
    - 'Teas and herbal teas and coffees'
    - 'Waters and flavored waters'
    - 'Fruit nectars'
- Alcoholic beverages
    - 'Alcoholic beverages'

4.2 Les informations nutritionelles (minimales)

- **68.6% des éléments sont non-vides**. Ca veut dire qu'il y a une valeur pour toutes les informations nutritionnelles (minimales) : énergie, matière grasse, acies gras saturés, glucides, sucres, protéins, sel (et sodium) qui sont, en générale, affichées obligatoirement sur les produits alimentaires.
- **De ces éléments, 5.7% des éléments sont écartés** parce qu'ils ont des valeurs érronées: les valeurs des variables ne sont pas cohérentes avec leurs définitions, leurs énergies nutritionnelles, la somme totale ou l'énergie nutrionnelle totale.
- **67.9% des éléments sont 'bien' renseignés**. Ce font **1 295 445 produits alimentaires** avec des informations nutionnelles potentiellement intéressantes.

- Pendent la nettoyage des données, **on peut déjà deviner certins clusters**.

4.3 Les classements et scores d'alimentation

Nutri-Score

- **36.6% des élements ont un Nutri-Score renseigné**: nutriscore_score et nutriscore_grade. Ces deux variables vont ensemble: soit toutes les deux categories sont reseignées soit toutes les deux sont vide. Le score détermine le classement.
- nutriscore_score_fr_100g est un doublon (à 5 éléments près) de nutriscore_score.
- nutriscore_score_uk_100g est effectivement vide avec que 9 éléments renseignés.
- **Des éléments renseignées, 98.9% sont 'bien' renseignés**. Leurs classement (nutriscore_grade) est cohérente avec le score (nutriscore_score).

NOVA catégories

- **32.4% des éléments ont été attribué à une NOVA catégorie.**
- Les éléments renseignés ont la distribution suivante:
  - 1.0 : 10.9 %
  - 2.0 : 1.9 %
  - 3.0 : 20.7 %
  - 4.0 : 66.5 %

Eco-Score

- **24.2% des éléments ont un eco-score renseigné**.
- Les éléments renseignés ont la distribution suivante:
  - a : 3.8 %
  - b : 26.8 %
  - c : 17.7 %
  - d : 33.5 %
  - e : 18.2 %
- La rélation entre le score et le classement est :
  - a : 80 - 125
  - b : 60 - 125
  - c : 40 - 59
  - d : 20 - 39
  - e : -28 - 19
  - Ce qu'a l'air d'être plutôt cohérente. Il doit avoir des critères qui distingues entre 'a' est 'b'.

4.4 Les codes à barré

Les codes n'ont pas tous le même format et il y a des duplicates. Les duplicates ne correspondent pas necessairement aux même produits. Il y a 1846 codes à barré dupliquées en comptant tous les dupliquants. (= max. 923 entrées << 1.9 Million)